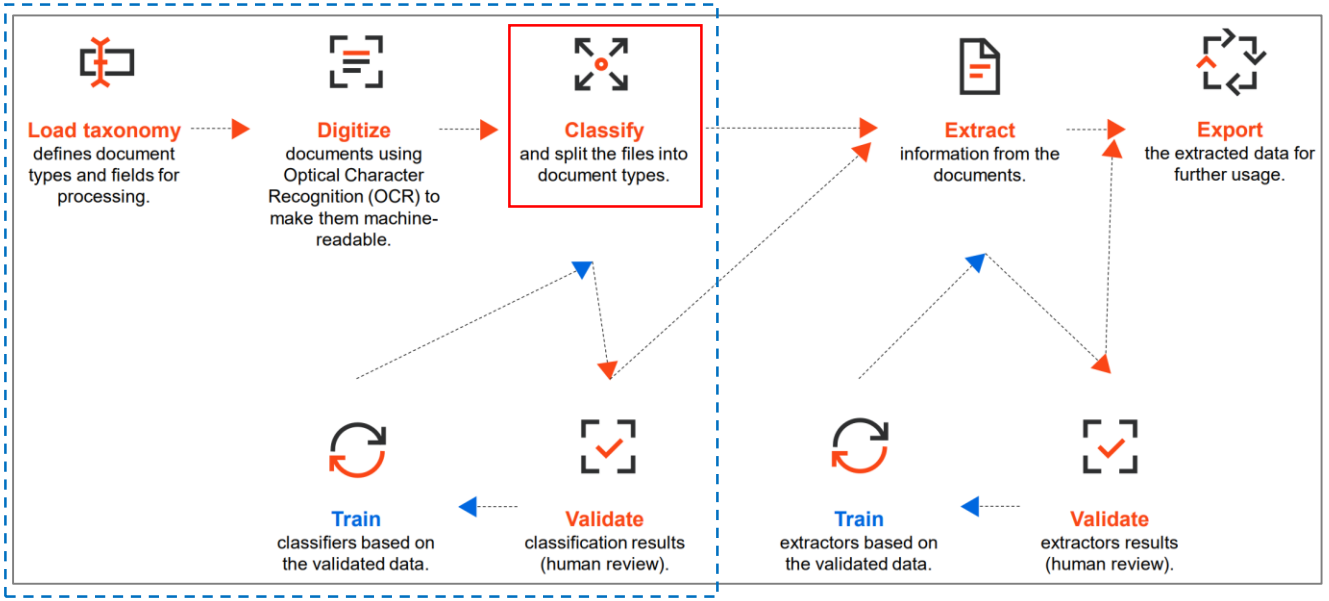
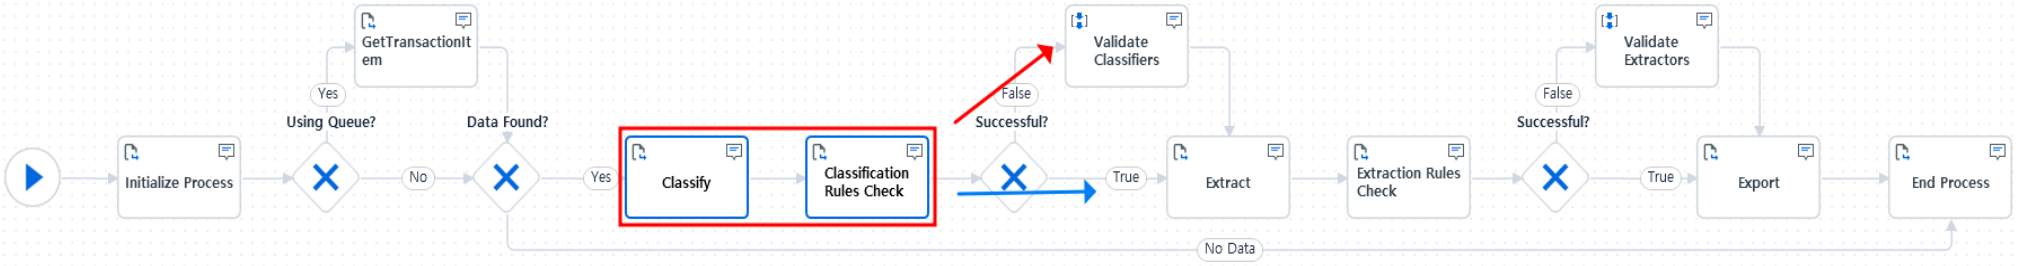
# 01 Document Classification 소개

## Document Classification이란 문서를 자동으로 분석하여 유형을 식별하고 분류하는 기술




Document Understanding Template






KCC정보통신

# IXP가 유리해도 Classic DU가 필요한 이유

신규 Cloud 환경은 IXP 우선 검토 | 재학습·규칙 기반·온프레미스 요건은 DU가 강점

### IXP | 도입·운영 효율

학습·호스팅 Unit 부담 ↓ · 복잡한 문서의 생성형 추출

### Classic DU | 모델·규칙 통제

학습 데이터 기반 개선 · 정형 문서 저비용 추출

| 비교 관점 | IXP (비정형·복잡 문서) | Classic DU (AI Center 기반) |
|---|---|---|
| **정확도 개선** | 프롬프트·추출 설정 조정 | 라벨 수정 → 전용 ML 모델 재학습 |
| **추출 방식** | 생성형 기반 복잡·비정형 문서 | ML + Form/RegEx 등 규칙 기반 |
| **운영 환경** | Cloud 기반 서비스 | 온프레미스·폐쇄망 선택 가능 |
| **비용 구조** | 학습·모델 호스팅 부담 적음 | 모델 학습·호스팅 비용 발생 가능 |

**선택 기준** **IXP 우선: 복잡한 문서·빠른 구축 | Classic DU 검토: 고객사별 반복 재학습·규칙 추출·폐쇄망**

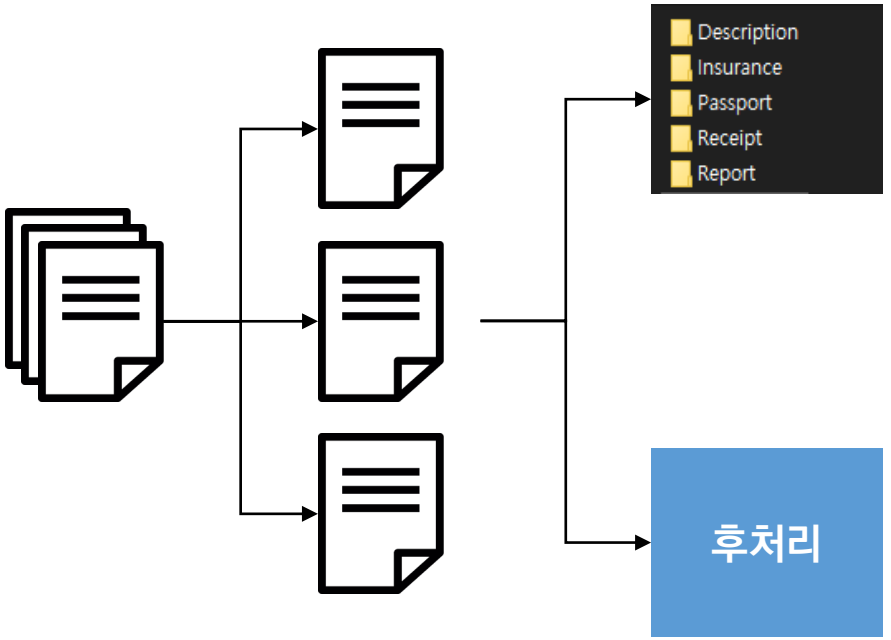
※ IXP는 비정형·복잡 문서 기능 기준. Communications Mining은 라벨 기반 학습 구조가 다름. 신규 구축 시 DU Modern도 함께 비교 필요.

# 02 Document Classification 구현 방향

## Classify 실제 구현 방향

- ✓ 다양한 더미의 파일을 받은 경우
- ✓ 작업자(개발자)
- ✓ DU PoC, 프로젝트 중
- ✓ 작업자의 필요에 따라 간략한 Classify 구현

- ✓ 문서 분류 자동화 프로세스 또는 기술검증 요청
- ✓ 고객사, 현업
- ✓ 분석, 설계 후 명확한 Classify 구현
- ✓ 후 처리 로직 (파일 유형별 DU추출, 시스템 업로드 등)



# 03 Classifier 종류 및 특징

| | 제품군<br>(AI Uint 포함) | 비용<br>(AI Unit) | 문서 유형 추천 | Page<br>Split | 학습 | Pipeline |
|---|---|---|---|---|---|---|
| Generative Classifier | Automation Cloud | 0.2 | 1. 구조화되지 않은 다양한 문서 유형<br>2. 자연어로 분류할 문서 유형이 명확 | X | X | X |
| Keyword Based Classifier | Automation Cloud<br>Automation Suite | 0 | 1. 파일 당 하나의 문서 유형만 포함<br>2. 세번째 페이지 이내 문서 유형과 관련된 키워드 포함 | X | △ | X |
| **Intelligence Keyword Classifier** | Automation Cloud<br>Automation Suite | 25p 당 1<br>(최대 5) | 1. 파일 내 하나 이상의 문서 유형<br>2. 내용 면에서 비교적 쉽게 구별 | O | O | X |
| Machine Learning Classifier | Automation Cloud<br>Automation Suite | 25p 당 1<br>(최대 5) | 1. 단일 문서를 분할할 필요 없이 여러 문서로 분류<br>2. 유사한 문서 유형을 더 쉽게 구별 | X | O | O |

# 04 Intelligence Keyword Classifier

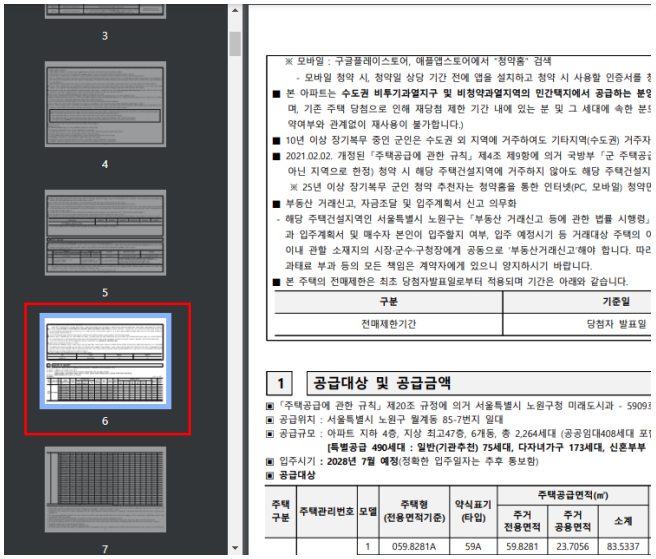
## 지능형 키워드 문서 분류 – 학습 결과


[{"DocumentKeywordVectors":[{"TotalDocumentLength":45752,"PageCount":6,"FirstPageVector":{"VectorId":"NoGroup.NoCategory.주택_공급금액_6.FirstPage","DocumentCount":2,"TermsWithScores":[{"Score":1.98,"Term":"특별공급","LastUpdated":"2024-11-26T16:26:29.1047323+09:00"},{"Score":1.82,"Term":"세대수","LastUpdated":"2024-11-26T16:26:29.1047293+09:00"},{"Score":1.6,"Term":"합계","LastUpdated":"2024-11-26T16:26:29.1047066+09:00"},{"Score":1.48,"Term":"기관추천","LastUpdated":"2024-11-26T16:26:29.1046587+09:00"},{"Score":1.48,"Term":"공급","LastUpdated":"2024-11-26T16:26:29.1046605+09:00"},{"Score":1.48,"Term":"충청남도","LastUpdated":"2024-11-26T16:26:29.1046734+09:00"},{"Score":1.48,"Term":"다자녀가구","LastUpdated":"2024-11-26T16:26:29.1046936+09:00"},{"Score":1.48,"Term":"총","LastUpdated":"2024-11-26T16:26:29.104712+09:00"},{"Score":1.48,"Term":"노부모부양자","LastUpdated":"2024-11-26T16:26:29.1047268+09:00"},{"Score":1.48,"Term":"천안시","LastUpdated":"2024-11-26T16:26:29.1047511+09:00"},{"Score":1.48,"Term":"생애최초","LastUpdated":"2024-11-26T16:26:29.1047793+09:00"},{"Score":1.48,"Term":"신혼부부","LastUpdated":"2024-11-26T16:26:29.1047866+09:00"},{"Score":1.46,"Term":"약식","LastUpdated":"2024-11-26T16:26:29.1046702+09:00"},{"Score":1.46,"Term":"표기","LastUpdated":"2024-11-26T16:26:29.1047338+09:00"},{"Score":1.46,"Term":"소계","LastUpdated":"2024-11-26T16:26:29.1047592+09:00"},{"Score":1.42,"Term":"공급세대수","LastUpdated":"2024-11-26T16:26:29.1047213+09:00"},{"Score":1.38,"Term":"공급금액","LastUpdated":"2024-11-26T16:26:29.1046687+09:00"},{"Score":1.38,"Term":"의거","LastUpdated":"2024-11-26T16:26:29.1046809+09:00"},{"Score":1.38,"Term":"규정에","LastUpdated":"2024-11-26T16:26:29.1046835+09:00"},{"Score":1.38,"Term":"규칙","LastUpdated":"2024-11-26T16:26:29.1046867+09:00"},{"Score":1.38,"Term":"레이크파크","LastUpdated":"2024-11-26T16:26:29.1046924+09:00"},{"Score":1.38,"Term":"공급내역","LastUpdated":"2024-11-26T16:26:29.1047561+09:00"},{"Score":1.38,"Term":"주택공급에","LastUpdated":"2024-11-26T16:26:29.1047605+09:00"},{"Score":1.38,"Term":"성성자이","LastUpdated":"2024-11-26T16:26:29.1047894+09:00"},{"Score":1.36,"Term":"승인","LastUpdated":"2024-11-26T16:26:29.1046619+09:00"},{"Score":1.36,"Term":"내역","LastUpdated":"2024-11-26T16:26:29.104665+09:00"},{"Score":1.36,"Term":"주택형","LastUpdated":"2024-11-26T16:26:29.1046792+09:00"},{"Score":1.36,"Term":"부대복리시설","LastUpdated":"2024-11-26T16:26:29.1046821+09:00"},{"Score":1.36,"Term":"일반분양","LastUpdated":"2024-11-26T16:26:29.1046911+09:00"},{"Score":1.36,"Term":"서북구","LastUpdated":"2024-11-26T16:26:29.1046964+09:00"},{"Score":1.36,"Term":"지하","LastUpdated":"2024-11-26T16:26:29.1047008+09:00"},{"Score":1.36,"Term":"입주예정시기","LastUpdated":"2024-11-26T16:26:29.1047079+09:00"},{"Score":1.36,"Term":"공급규모","LastUpdated":"2024-11-26T16:26:29.1047109+09:00"},{"Score":1.36,"Term":"관리번호","LastUpdated":"2024-11-26T16:26:29.1047153+09:00"},{"Score":1.36,"Term":"일원","LastUpdated":"2024-11-26T16:26:29.1047184+09:00"},{"Score":1.36,"Term":"추후","LastUpdated":"2024-11-26T16:26:29.1047228+09:00"},{"Score":1.36,"Term":"주택","LastUpdated":"2024-11-26T16:26:29.1047243+09:00"},{"Score":1.36,"Term":"입주자모집공고","LastUpdated":"2024-11-26T16:26:29.1047279+09:00"},{"Score":1.36,"Term":"통보","LastUpdated":"2024-11-26T16:26:29.1047353+09:00"},{"Score":1.36,"Term":"아파트","LastUpdated":"2024-11-26T16:26:29.1047367+


- ✓ 페이지의 단어들이 json파일에 저장
- ✓ 누적 학습에 따라 가중치(Score)가 변경
- ✓ 가중치가 낮을 경우 임의 수정으로 해당 키워드에 대한 분류를 향상시킬 수 있지만 일정 수준의 학습 후엔 판별에 오류가 될 수 있음

# 04 Intelligence Keyword Classifier

## 지능형 키워드 문서 분류 – 분류 결과



※ 모바일 : 구글플레이스토어, 애플앱스토어에서 "청약홈" 검색
- 모바일 청약 시, 청약일 상당 기간 전에 앱을 설치하고 청약 시 사용할 인증서를 ...

■ 본 아파트는 **수도권 비투기과열지구 및 비청약과열지역의 민간택지에서 공급하는 분양**...
며, 기존 주택 당첨으로 인해 재당첨 제한 기간 내에 있는 분 및 그 세대에 속한 분...
약여부와 관계없이 재사용이 불가합니다.)

■ 10년 이상 장기복무 중인 군인은 수도권 외 지역에 거주하여도 기타지역(수도권) 거주자...

■ 2021.02.02. 개정된 「주택공급에 관한 규칙」 제4조 제9항에 의거 국방부 「군 주택공급...
아닌 지역으로 한정) 청약 시 해당 주택건설지역에 거주하지 않아도 해당 주택건설지...
※ 25년 이상 장기복무 군인 청약 추천자는 청약홈을 통한 인터넷(PC, 모바일) 청약만...

■ 부동산 거래신고, 자금조달 및 입주계획서 신고 의무화
- 해당 주택건설지역인 서울특별시 노원구는 「부동산 거래신고 등에 관한 법률 시행령」...
과 입주계획서 및 매수자 본인이 입주할지 여부, 입주 예정시기 등 거래대상 주택의 ...
이내 관할 소재지의 시장·군수·구청장에게 공동으로 '부동산거래신고'해야 합니다. 따라...
과태료 부과 등의 모든 책임은 계약자에게 있으니 양지하시기 바랍니다.

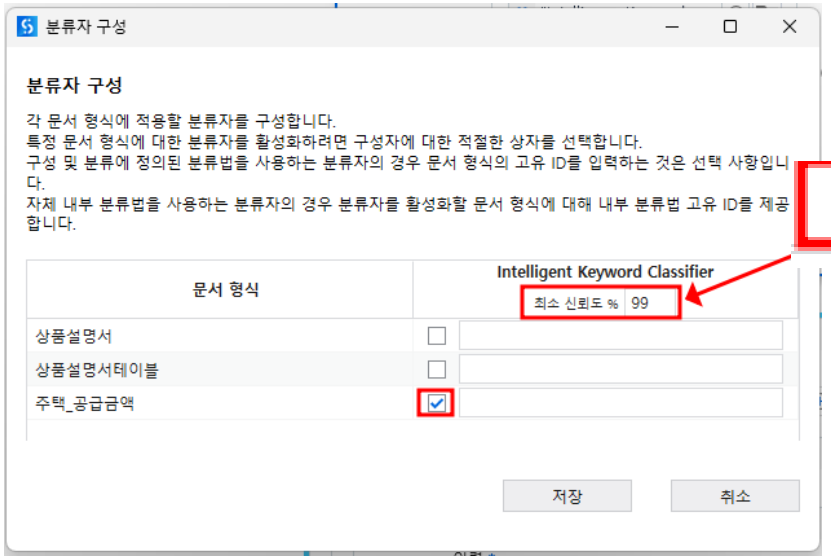
■ 본 주택의 전매제한은 최초 당첨자발표일로부터 적용되며 기간은 아래와 같습니다.

| 구분 | 기준일 |
|---|---|
| 전매제한기간 | 당첨자 발표일 |

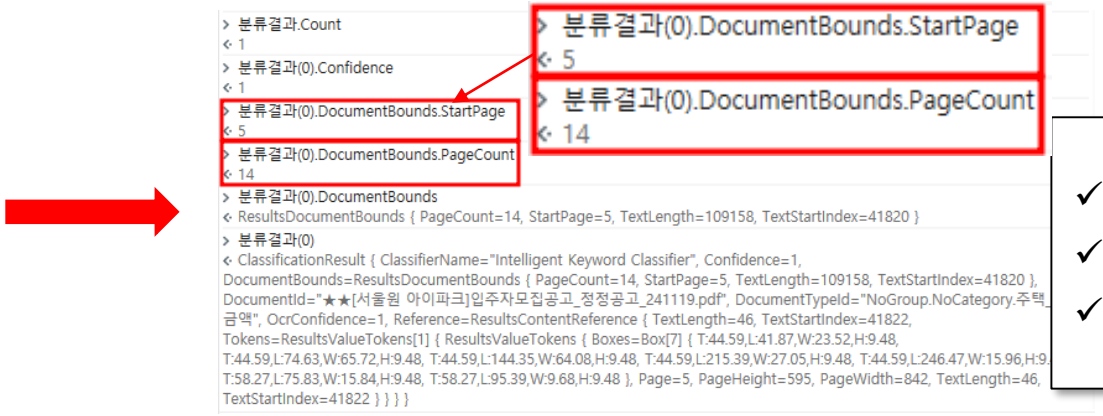
**1 공급대상 및 공급금액**

▣ 「주택공급에 관한 규칙」 제20조 규정에 의거 서울특별시 노원구청 미래도시과 - 5909...
▣ 공급위치 : 서울특별시 노원구 월계동 85-7번지 일대
▣ 공급규모 : 아파트 지하 4층, 지상 최고47층, 6개동, 총 2,264세대 (공공임대408세대 포...
**[특별공급 490세대 : 일반(기관추천) 75세대, 다자녀가구 173세대, 신혼부부...**
▣ 입주시기 : **2028년 7월 예정**(정확한 입주일자는 추후 통보함)
▣ 공급대상

| 주택 구분 | 주택관리번호 | 모델 | 주택형 (전용면적기준) | 약식표기 (타입) | 주택공급면적(㎡) | | |
|---|---|---|---|---|---|---|---|
| | | | | | 주거 전용면적 | 주거 공용면적 | 소계 |
| | | 1 | 059.8281A | 59A | 59.8281 | 23.7056 | 83.5337 |




최소 신뢰도 % 99




분류결과(0).DocumentBounds.StartPage
5

분류결과(0).DocumentBounds.PageCount
14

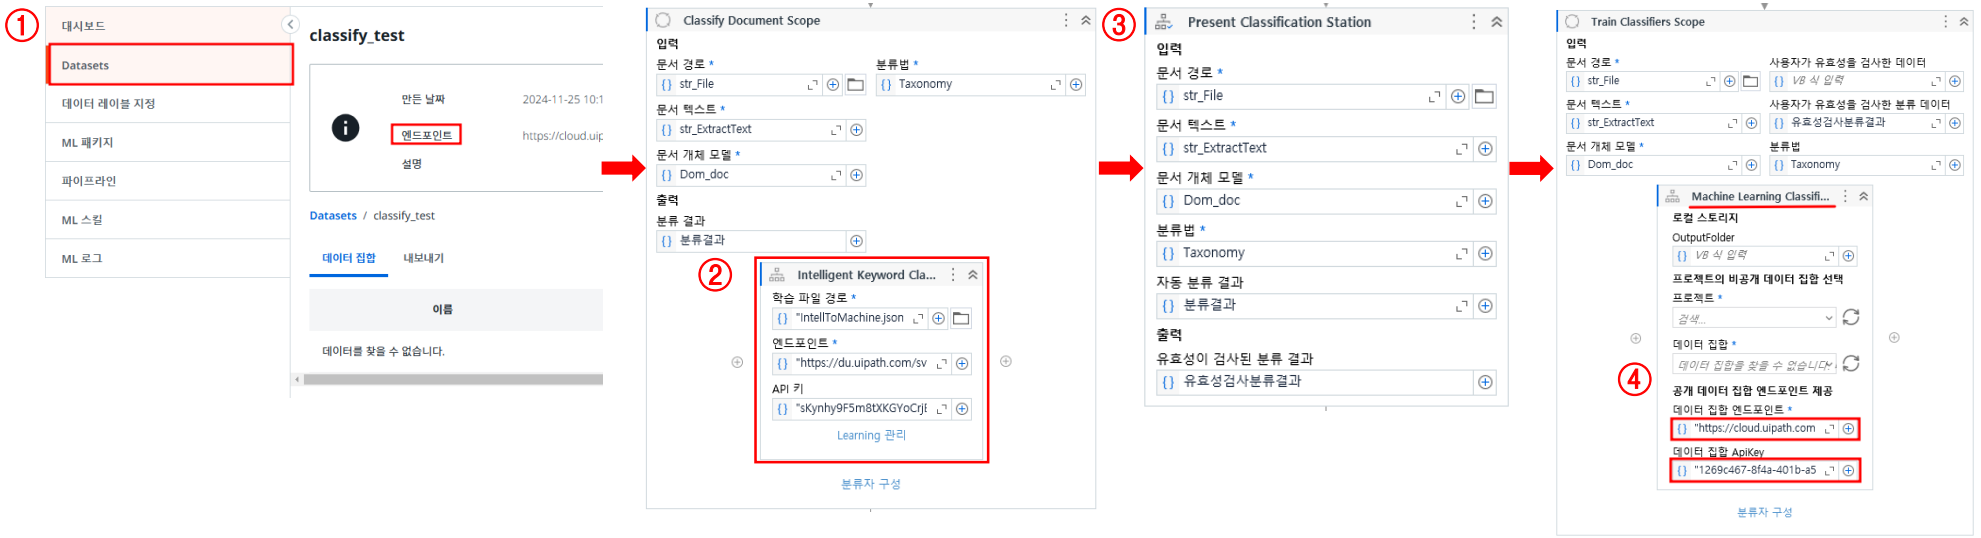
- ✓ **분류 시 최소 신뢰도 중요**
- ✓ **1% 차이로도 다른 페이지가 더 추출될 수 있음**
- ✓ **Confidence도 확인하면서 테스트 필요**



KCC정보통신

# 05 Machine Learning Classifier

## MLSkill을 사용하여 머신러닝 문서 분류 – 학습




1. DU 데이터셋 생성 (학습 시 키워드 데이터가 적재)
2. 선 분류는 편리한 방법으로 선택
(Keyword, Intelligence 등 간단한 구현)
3. Station으로 검증
4. Train Scope에서 데이터집합으로 학습 적재



KCC정보통신

# 05 Machine Learning Classifier

## 학습 – 데이터가 Dataset에 적재

Datasets / classify_test

데이터 집합 내보내기

| 이름 | 크기 | 형식 | 생성됨 |
|---|---|---|---|
| NoGroup.NoCategory.상품설명서테이블 | -- | 디렉터리 | |

Datasets / classify_test / NoGroup.NoCategory.상품설명서테이블

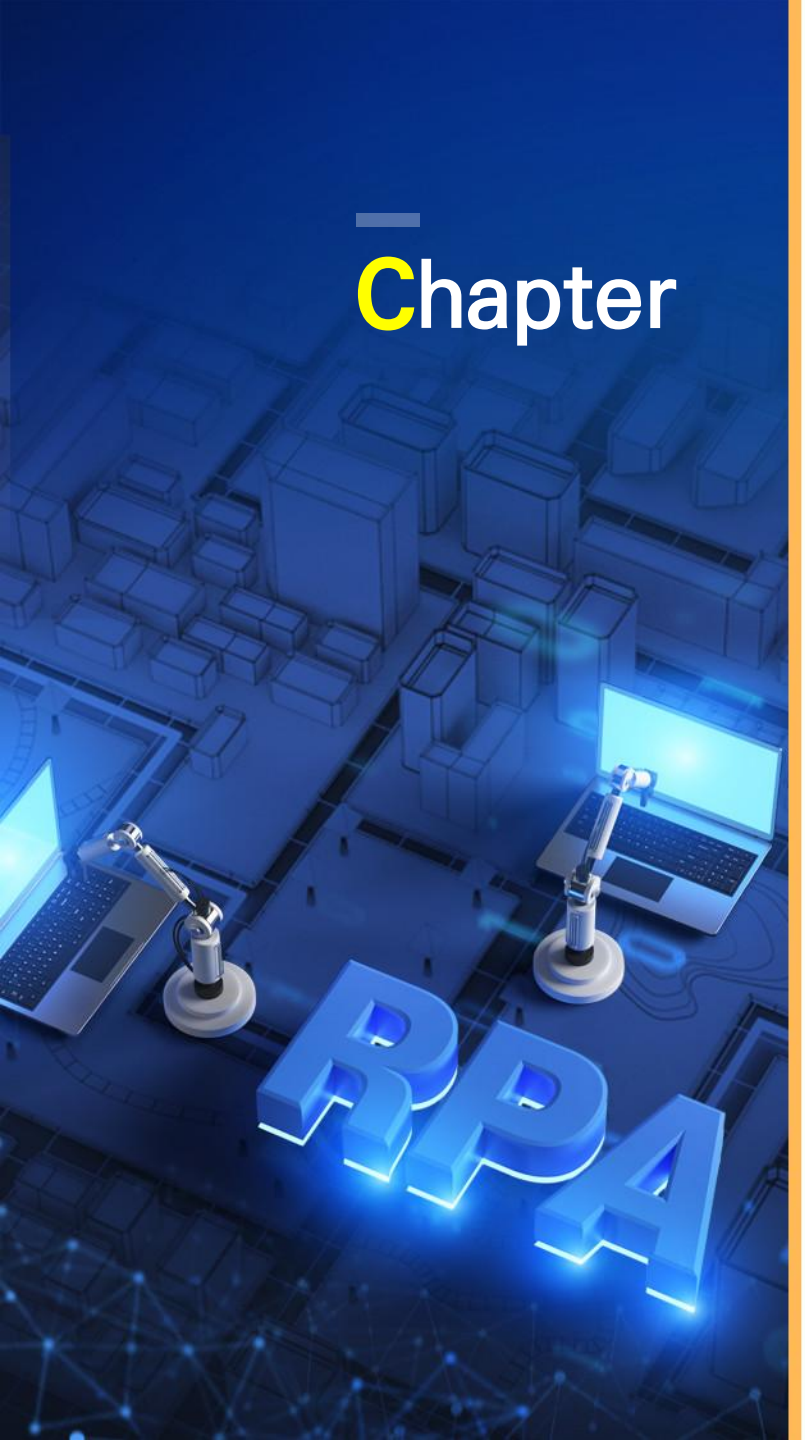
데이터 집합 내보내기

| 이름 | 크기 | 형식 | 생성됨 |
|---|---|---|---|
| (2024.01.30) 전세안심대출.pdf_p0-8_2024-12-05-13-50-04.txt | 21.5 kB | | |



OOO전세안심대

- ✓ 유형 이름으로 디렉토리가 생성
- ✓ 디렉토리에 OCR 추출된 텍스트 문서가 적재됨
- ✓ DU 라벨링과 다르게 텍스트만 저장
- ✓ 텍스트의 위치 등 정보 없음. DU와 동일한 성능 X



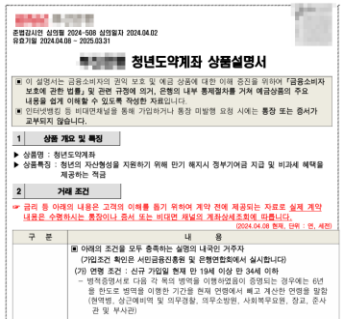

# DU 실무 가이드 (Tips)

1. Classifier 정확도
2. DU 학습 파일이 부족한 경우(PDF)
3. 유효성 검사 파일 변경 방법
4. 데이터 필드 〈 레귤러 필드

# 01 Classifier 정확도

## Intelligence Keyword 〈 Machine Learning

### 다른 유형 문서



청년도약계좌 상품설명서

1 상품 개요 및 특징

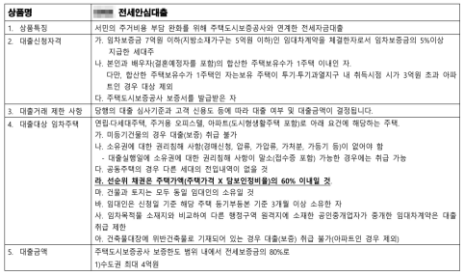
▶ 상품명 : 청년도약계좌
▶ 상품특징 : 청년의 자산형성을 지원하기 위해 한기 해지시 정부기여금 지급 및 비과세 혜택을 제공하는 적금

2 거래 조건

☞ 금리 등 아래의 내용은 고객의 이해를 돕기 위하여 계약 전에 제공되는 자료로 실제 계약 내용은 수행하시는 통장이나 증서 또는 비대면 채널의 계좌상세조회에 따릅니다.

(2024.04.08 현재, 단위 : 연, 세전)

| 구 분 | 내 용 |
|---|---|
| | ▣ 아래의 조건을 모두 충족하는 실명의 내국인 거주자<br>(가입조건 확인은 서민금융진흥원 및 은행연합회에서 실시합니다) |
| | (가) 연령 조건 : 신규 가입일 현재 만 19세 이상 만 34세 이하 |



| 상품명 | 전세안심대출 |
|---|---|
| 1. 상품특징 | 서민의 주거비용 부담 완화를 위해 주택도시보증공사와 연계한 전세자금대출 |
| 2. 대출신청자격 | 가. 임차보증금 7억원 이하(지방소재가구는 5억원 이하)인 임대차계약을 체결한자로서 임차보증금의 5%이상 지급한 세대주<br>나. 본인과 배우자(결혼예정자를 포함)의 합산한 주택보유수가 1주택 이내인 자.<br>다만, 합산한 주택보유수가 1주택인 자는보유 주택이 투기투기과열지구 내 취득시점 시가 3억원 초과 아파트인 경우 대상 제외<br>다. 주택도시보증공사 보증서를 발급받은 자 |
| 3. 대출거래 제한 사항 | 당행의 대출 심사기준과 고객 신용도 등에 따라 대출 여부 및 대출금액이 결정됩니다. |
| 4. 대출대상 임차주택 | 연립·다세대주택, 주거용 오피스텔, 아파트(도시형생활주택 포함)로 아래 요건에 해당하는 주택.<br>가. 미등기건물의 경우 대출(보증) 취급 불가<br>나. 소유권에 대한 권리침해 사항(경매신청, 압류, 가압류, 가처분, 가등기 등)이 없어야 함<br>- 대출실행일에 소유권에 대한 권리침해 사항이 발소(집수증 포함) 가능한 경우에는 취급 가능<br>다. 공동주택의 경우 다른 세대의 전입세대이 없을 것<br>**라. 선순위 채권은 주택가액(주택가격 X 담보인정비율)의 60% 이내일 것**<br>마. 건물과 토지는 모두 동일 임대인의 소유일 것<br>바. 임대인은 신청일 기준 해당 주택 등기부등본 기준 3개월 이상 소유한 자<br>사. 임차목적물 소재지와 비교하여 다른 행정구역 읍·면·지역 소재한 공인중개업자가 중개한 임대차계약은 대출취급 제한<br>아. 건축물대장에 위반건축물로 기재되어 있는 경우 대출(보증) 취급 불가(아파트인 경우 제외) |
| 5. 대출금액 | 주택도시보증공사 보증한도 범위 내에서 전세보증금의 80%로<br>1)수도권 최대 4억원 |

### 같은 유형 문서

| Date | 2024.01.01 | Version | 1.0 | Page No | 5 / 10 |
|---|---|---|---|---|---|

| 모집 공고 | | | | | |
|---|---|---|---|---|---|
| 주택유형 | 민영 | 해당지역 | 인천 | 규제여부 | 비규제 |

| No | TYPE | 예치금액 | 발코니 | 중문 | 주방옵션 |
|---|---|---|---|---|---|
| 1 | 59A | 3,000,000 | 5,000,000 | 1,160,000 | 1,960,000 |
| 2 | 59B | 3,000,000 | 3,500,000 | 1,120,000 | 2,290,000 |
| 3 | 84A | 6,000,000 | 7,000,000 | 1,160,000 | 2,360,000 |
| 4 | 84B | 6,000,000 | 4,600,000 | 1,120,000 | 2,220,000 |
| 5 | 99A | 6,000,000 | 7,120,000 | 1,160,000 | 2,560,000 |

| Date | 2024.01.01 | Version | 1.0 | Page No | 3 / 15 |
|---|---|---|---|---|---|

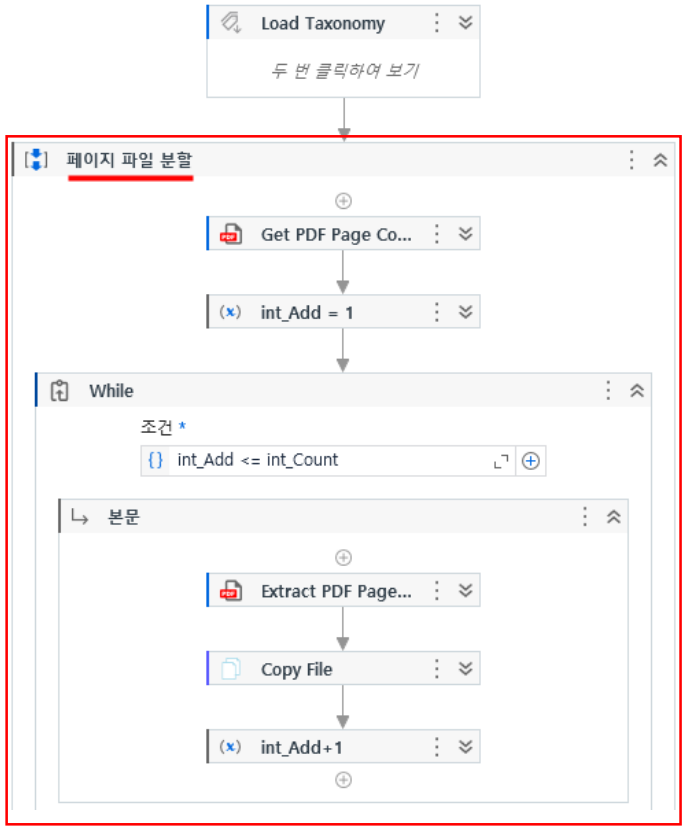
| 지원 공고 | | | | | |
|---|---|---|---|---|---|
| 주택유형 | 공공 | 해당지역 | 서울 | 규제여부 | 비규제 |

| No | TYPE | 임대료 지원 | 관리비 지원 | 보조금 | 특별 지원금 |
|---|---|---|---|---|---|
| 1 | 59A | 1,500,000 | 300,000 | 2,000,000 | 500,000 |
| 2 | 59B | 1,800,000 | 350,000 | 2,200,000 | 600,000 |
| 3 | 84A | 2,000,000 | 400,000 | 2,500,000 | 700,000 |
| 4 | 84B | 2,500,000 | 450,000 | 3,000,000 | 800,000 |
| 5 | 99A | 3,000,000 | 500,000 | 3,500,000 | 1,000,000 |

| | Intelligence Keyword Classifier | | Machine Learning Classifier | |
|---|---|---|---|---|
| 다른 유형 | 10 / 10 | 100% | 10 / 10 | 100% |
| 같은 유형 (엑셀, 템플릿) | 0 / 10 | 0% | 7 / 10 | 70% |

# 01 Classifier 정확도

## Intelligence Keyword Classifier와 같이 페이지 분류 방법







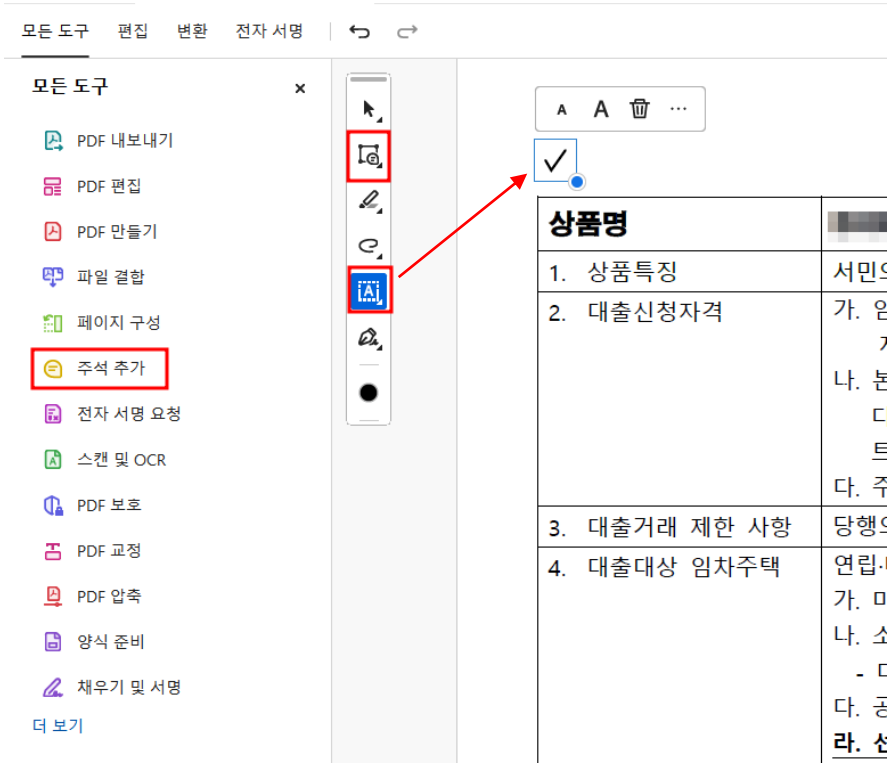


KCC정보통신

# 02 DU 학습 파일이 부족한 경우

## PDF 파일 복제 방법(PDF 라이선스 없을 경우)

- ✓ 파일 형식 : PDF
- ✓ 아크로벳 라이선스가 없는 경우
- ✓ 주석 추가 또는 전자 서명 추가 기능을 사용
- ✓ 데이터와 무관한 영역에 주석 또는 서명 추가
- ✓ **DU 업로드 시 다른 파일로 인식하여 중복 업로드 가능**



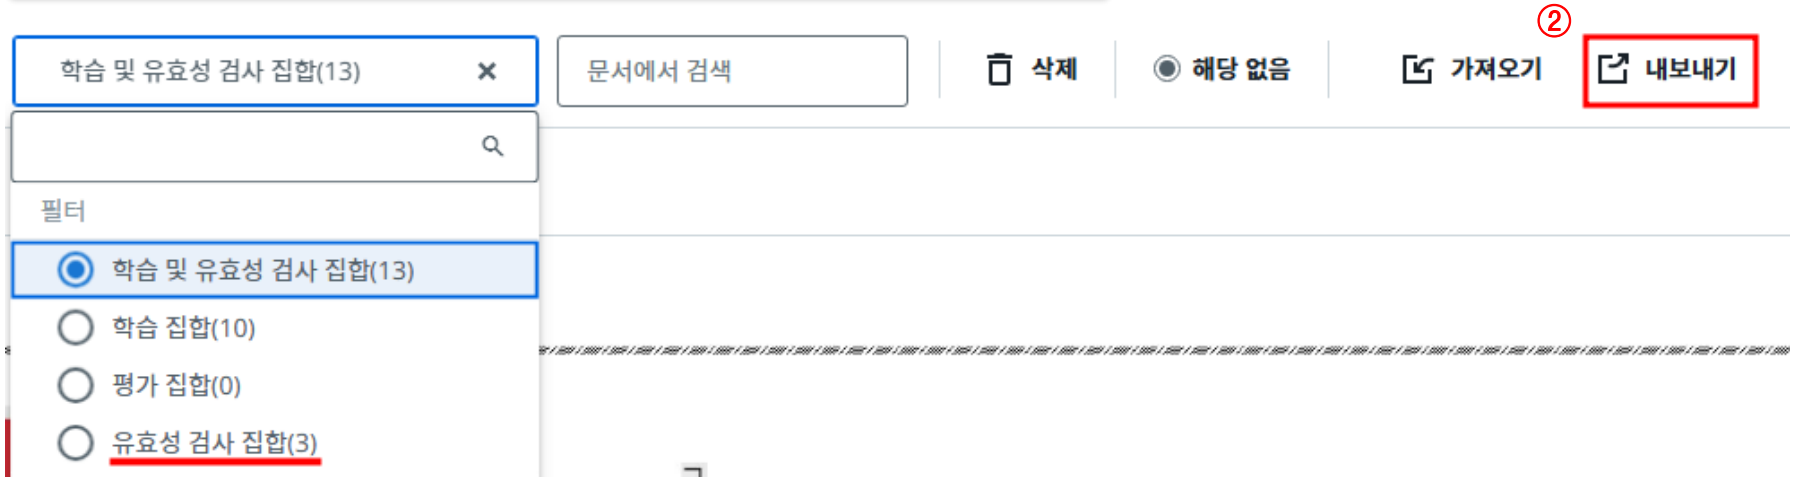



KCC정보통신

# 03 유효성 검사 파일 변경 방법

## 유효성 검사 집합 수정 방법

- ✓ 학습 파일이 부족한 경우
- ✓ 파일 업로드 시 DU에서 임의로 학습집합, 유효성 검사 집합을 나눔
- ✓ 라벨링 세션 파일을 로컬로 받아 구성 파일을 직접 수정 가능
- ✓ **유효성 검사 집합을 모두 제거할 수는 없음**



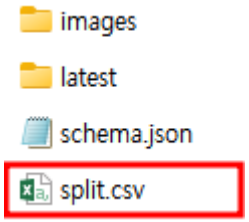


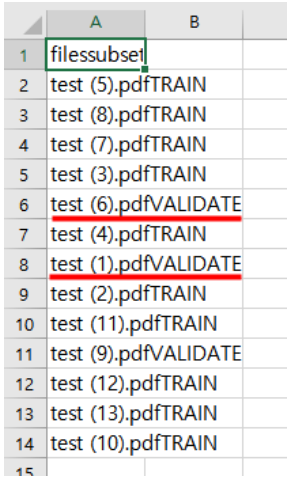

KCC정보통신

# 03 유효성 검사 파일 변경 방법

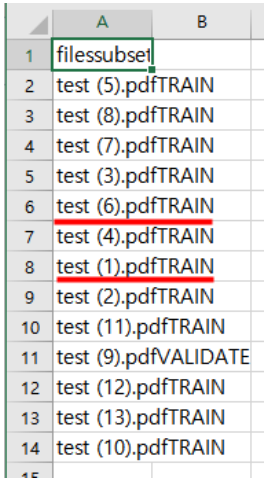
## split 파일, json파일 수정

① split.csv 수정



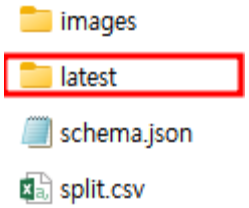



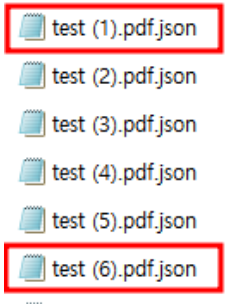
| | A | B |
|---|---|---|
| 1 | filessubset | |
| 2 | test (5).pdfTRAIN | |
| 3 | test (8).pdfTRAIN | |
| 4 | test (7).pdfTRAIN | |
| 5 | test (3).pdfTRAIN | |
| 6 | test (6).pdfVALIDATE | |
| 7 | test (4).pdfTRAIN | |
| 8 | test (1).pdfVALIDATE | |
| 9 | test (2).pdfTRAIN | |
| 10 | test (11).pdfTRAIN | |
| 11 | test (9).pdfVALIDATE | |
| 12 | test (12).pdfTRAIN | |
| 13 | test (13).pdfTRAIN | |
| 14 | test (10).pdfTRAIN | |

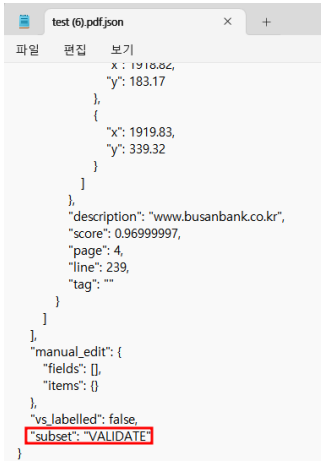


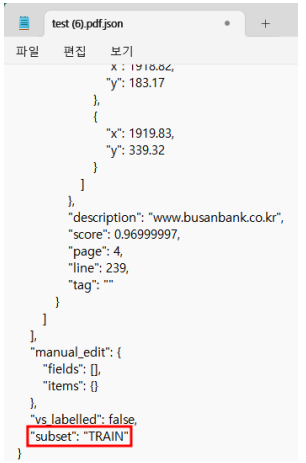
| | A | B |
|---|---|---|
| 1 | filessubset | |
| 2 | test (5).pdfTRAIN | |
| 3 | test (8).pdfTRAIN | |
| 4 | test (7).pdfTRAIN | |
| 5 | test (3).pdfTRAIN | |
| 6 | test (6).pdfTRAIN | |
| 7 | test (4).pdfTRAIN | |
| 8 | test (1).pdfTRAIN | |
| 9 | test (2).pdfTRAIN | |
| 10 | test (11).pdfTRAIN | |
| 11 | test (9).pdfVALIDATE | |
| 12 | test (12).pdfTRAIN | |
| 13 | test (13).pdfTRAIN | |
| 14 | test (10).pdfTRAIN | |

② json 수정






KCC정보통신

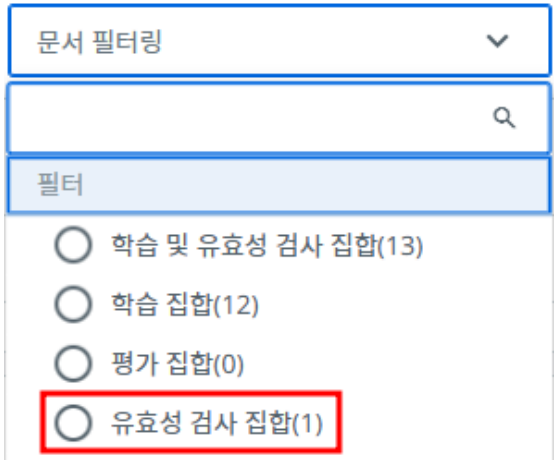
# 03 유효성 검사 파일 변경 방법

## 재압축 후 파일 업로드

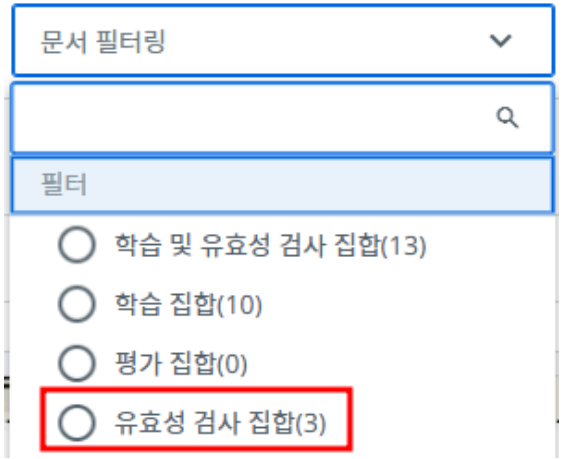
③ 압축한 파일 라벨링 세션 업로드




Before



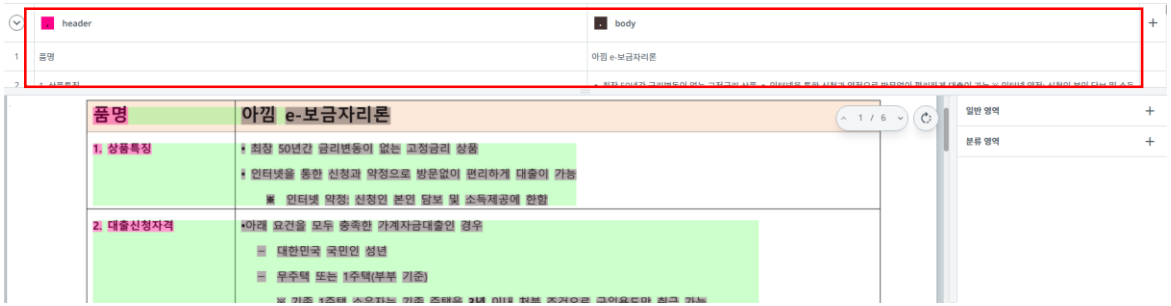

After



# 04 데이터 필드 〈 레귤러 필드

## 정확도 향상을 위한 라벨링 세션 세팅

1 데이터 필드




2 레귤러 필드






KCC정보통신

# DU 프로젝트 일정 산정의 사각지대

라벨링·학습 공수를 반영해도, 분류 품질 확보와 대량 데이터 검증을 놓치면 일정 지연이 발생합니다.




**일정 영향** — 선행 분류 지연 + 검증·개선 반복 → 추출 개발·검수·안정화 일정 지연

권장: WBS에 '문서 분류 품질 확보'와 '데이터 정합성 분석·재검증'을 독립 공정으로 편성