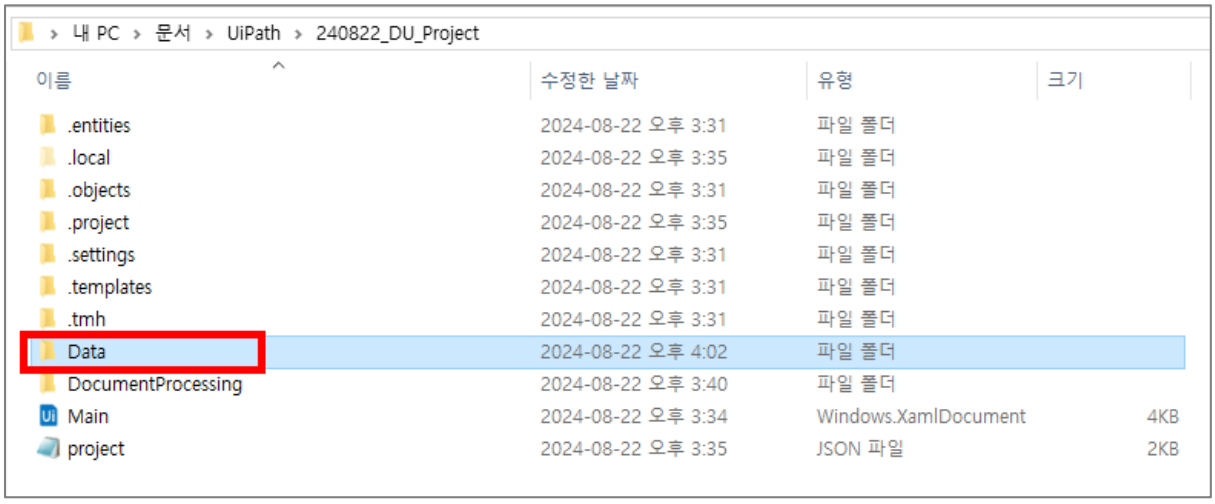
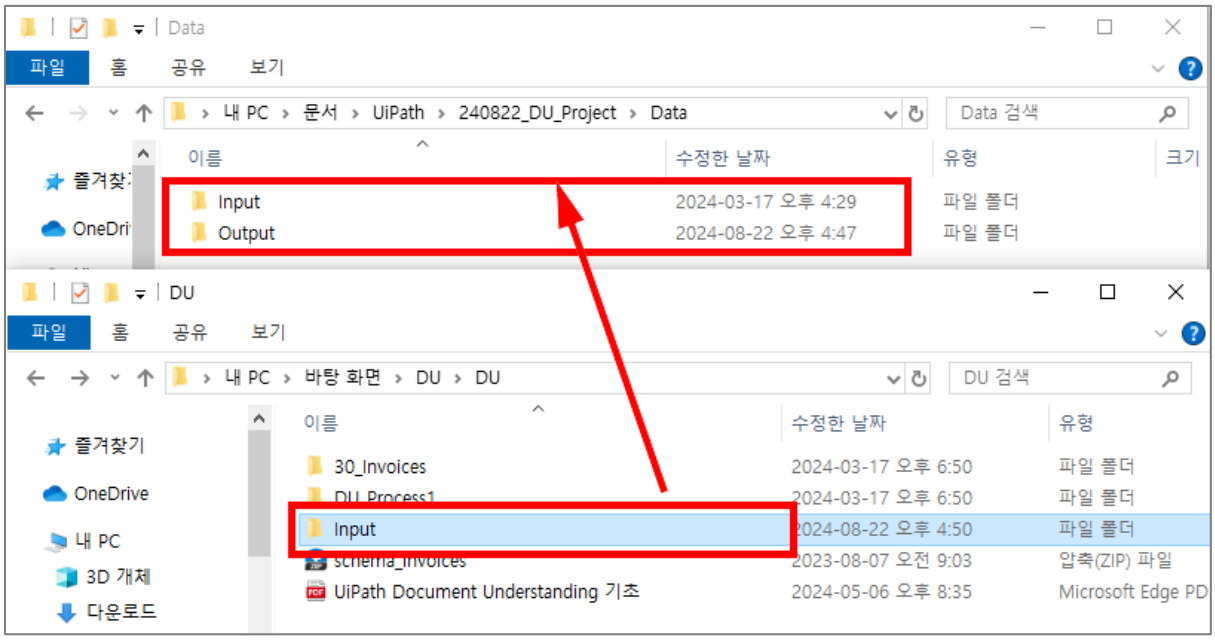
1.2. 프로젝트 폴더 관리

Step1. 프로젝트 폴더 내 ‘Data’ 폴더 생성



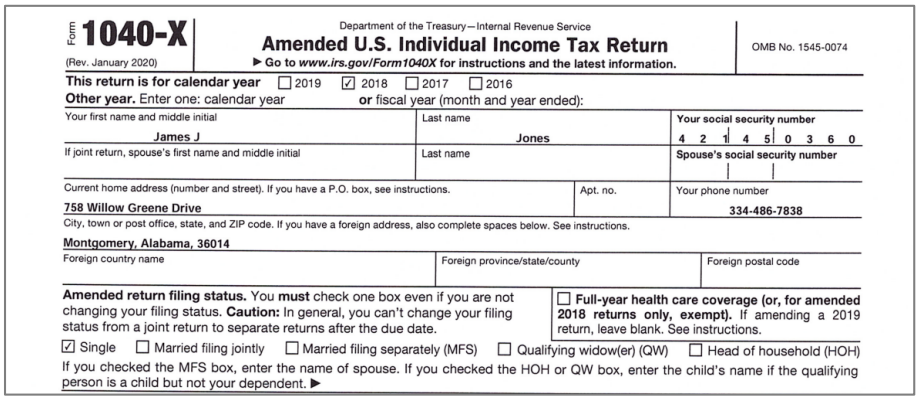
Step2. ‘Data’ 폴더 내 ‘실습 폴더 Input 폴더’ 드래그 앤 드롭 후, Output 폴더도 생성



1.3. Document Understanding을 진행할 문서 확인

1.3.1. 정형(Rule-Based) 방식으로 진행할 문서

- Data\Input\04-form.pdf



Form **1040-X** (Rev. January 2020)

Department of the Treasury—Internal Revenue Service

Amended U.S. Individual Income Tax Return

► Go to *www.irs.gov/Form1040X* for instructions and the latest information.

OMB No. 1545-0074

This return is for calendar year ☐ 2019 ☑ 2018 ☐ 2017 ☐ 2016

Other year. Enter one: calendar year **or** fiscal year (month and year ended):

Your first name and middle initial	Last name	Your social security number
James J	Jones	4 2 1 4 5 0 3 6 0
If joint return, spouse's first name and middle initial	Last name	Spouse's social security number

Current home address (number and street). If you have a P.O. box, see instructions.	Apt. no.	Your phone number
758 Willow Greene Drive		334-486-7838

City, town or post office, state, and ZIP code. If you have a foreign address, also complete spaces below. See instructions.

Montgomery, Alabama, 36014

Foreign country name	Foreign province/state/county	Foreign postal code

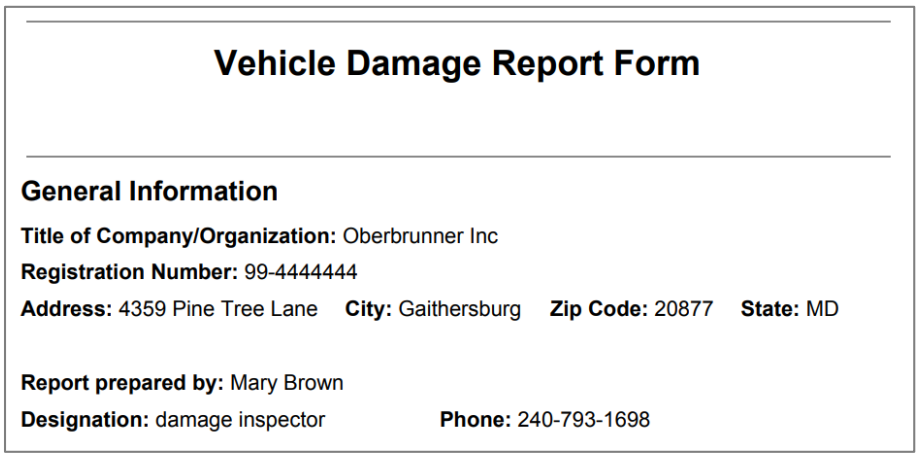
Amended return filing status. You **must** check one box even if you are not changing your filing status. **Caution:** In general, you can't change your filing status from a joint return to separate returns after the due date.

☐ **Full-year health care coverage (or, for amended 2018 returns only, exempt).** If amending a 2019 return, leave blank. See instructions.

☑ Single ☐ Married filing jointly ☐ Married filing separately (MFS) ☐ Qualifying widow(er) (QW) ☐ Head of household (HOH)

If you checked the MFS box, enter the name of spouse. If you checked the HOH or QW box, enter the child's name if the qualifying person is a child but not your dependent. ►

- Data\Input\02-damage-report.pdf



Vehicle Damage Report Form

General Information

Title of Company/Organization: Oberbrunner Inc

Registration Number: 99-4444444

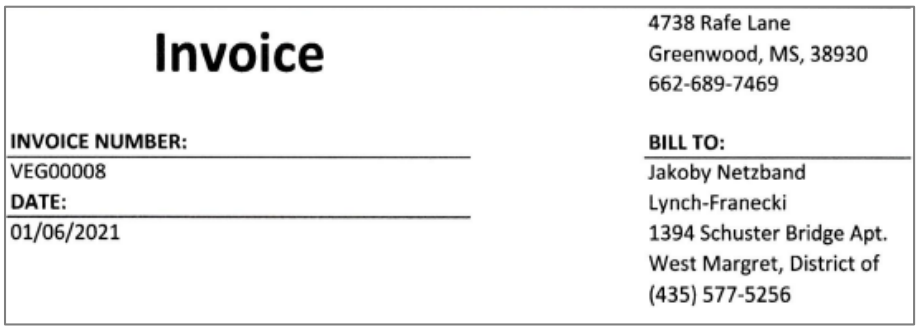
Address: 4359 Pine Tree Lane **City:** Gaithersburg **Zip Code:** 20877 **State:** MD

Report prepared by: Mary Brown

Designation: damage inspector **Phone:** 240-793-1698

1.3.2. 반정형(Model-Based) 방식으로 진행할 문서

- Data\Input\03-invoice.pdf



Invoice

4738 Rafe Lane
Greenwood, MS, 38930
662-689-7469

INVOICE NUMBER:
VEG00008

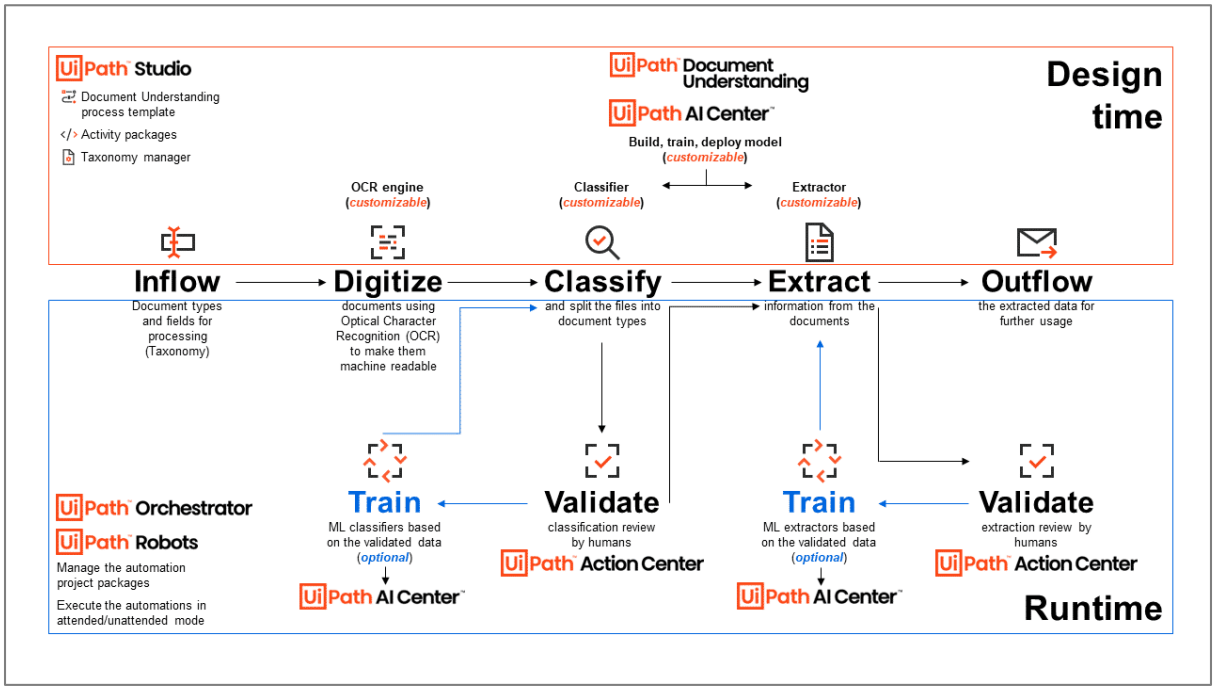
DATE:
01/06/2021

BILL TO:
Jakoby Netzband
Lynch-Franecki
1394 Schuster Bridge Apt.
West Margret, District of
(435) 577-5256

1.4. 프로세스 작성

1.4.1. DU 기본 Workflow 확인

- UiPath Studio 에서 기본 Workflow 순서대로 개발을 진행하도록 하겠습니다.

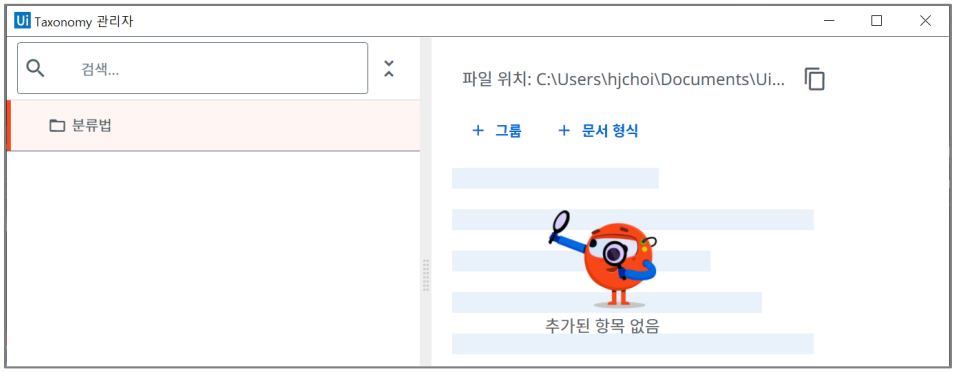


1.4.2. Taxonomy 관리자 편집

- 처리할 문서 유형과 필드를 정의합니다.

Step1. 리본 메뉴 – Taxonomy 관리자 메뉴 클릭





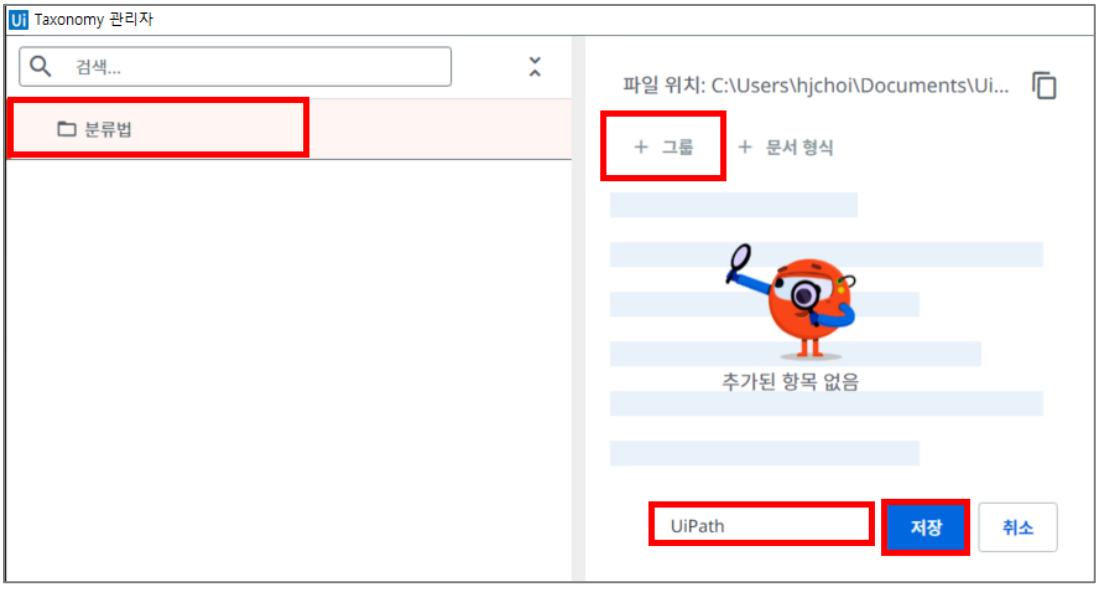
핵심 포인트

만약, Taxonomy 관리자가 열렸지만, 글자가 써지지 않는다면 그래픽 카드 업데이트가 필요한 상황입니다.

Step2. 그룹 생성

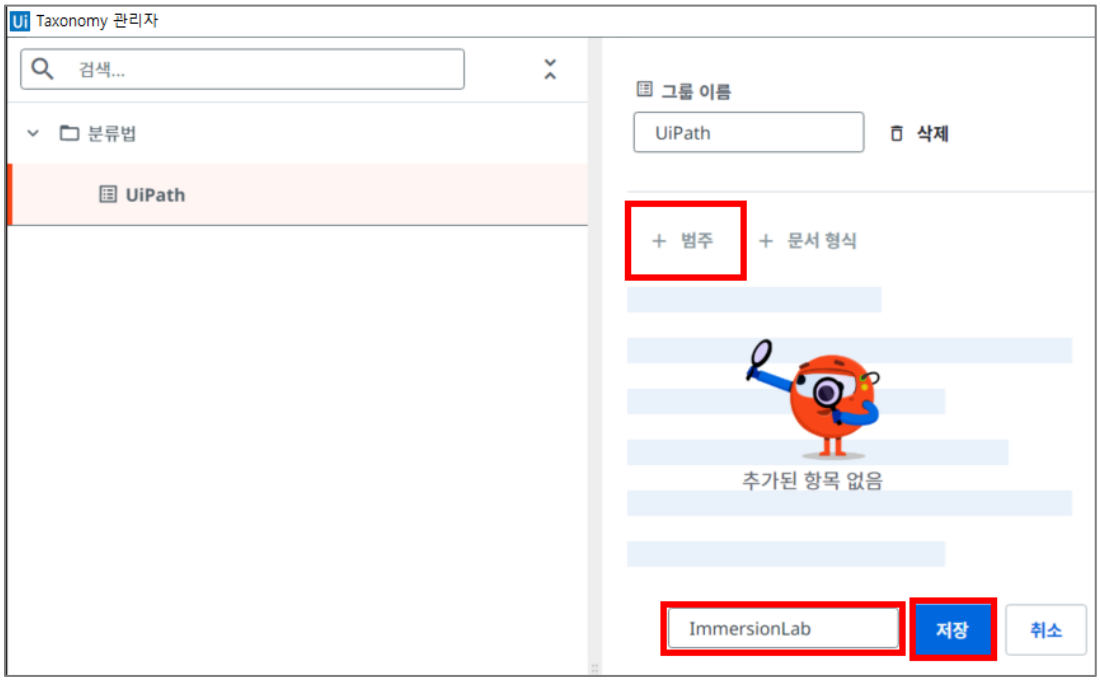
- 가장 상위 계층으로 여러 범주들의 집합입니다. 여기서는 어떤 문서를 분류할 것인지 정할 수 있습니다. (Ex: 회계 문서, 인사 문서 등)

5



Step3. 범주 생성

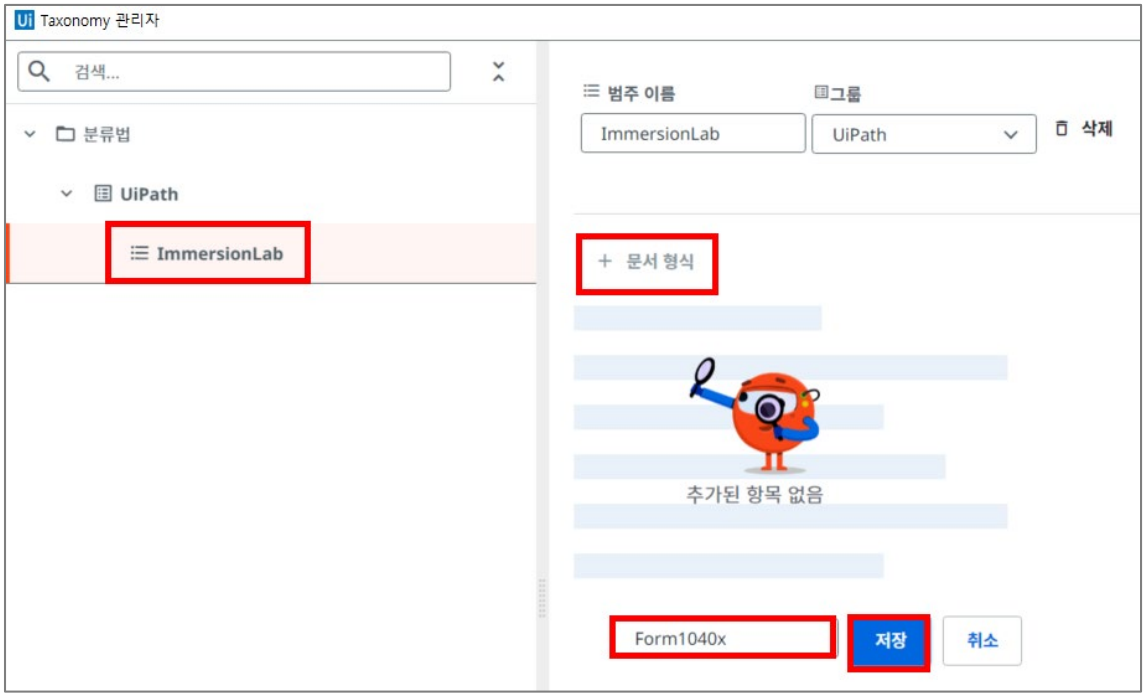
- 그룹 내에서의 하위 계층으로 특정 그룹 내에서 문서의 세부 분류에 사용됩니다. (Ex: 그룹이 회계 문서일 경우, 범주는 송장, 영수증 등)



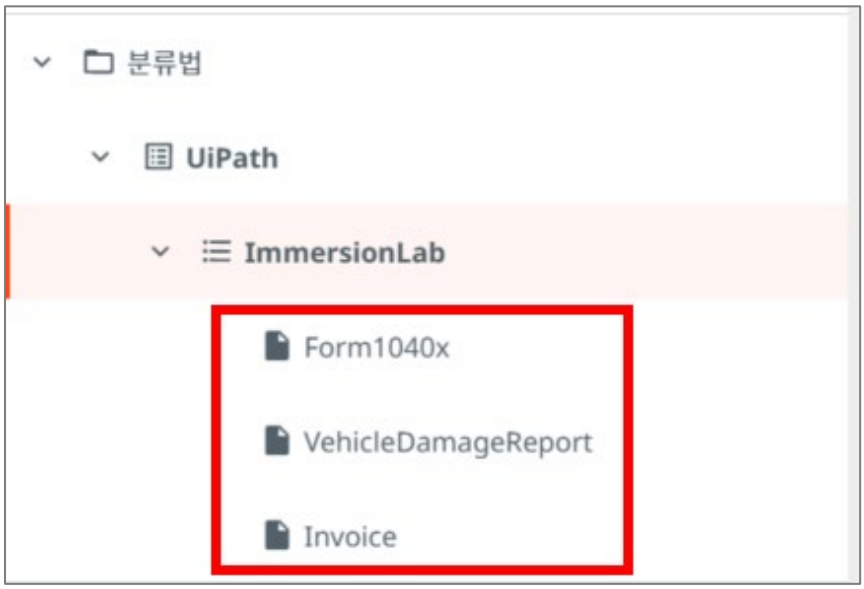
Step4. 문서 형식 생성 (Form1040x, Vehicle Damage Report, Invoice)

- 범주 내에서의 하위 계층입니다. 특정 범주 내의 문서의 더욱 세부적인 분류에 사용됩니다.

(Ex: 범주가 송장인 경우, 문서 형식은 전자 송장, 대면 송장 등)



- 각 문서 형식 생성

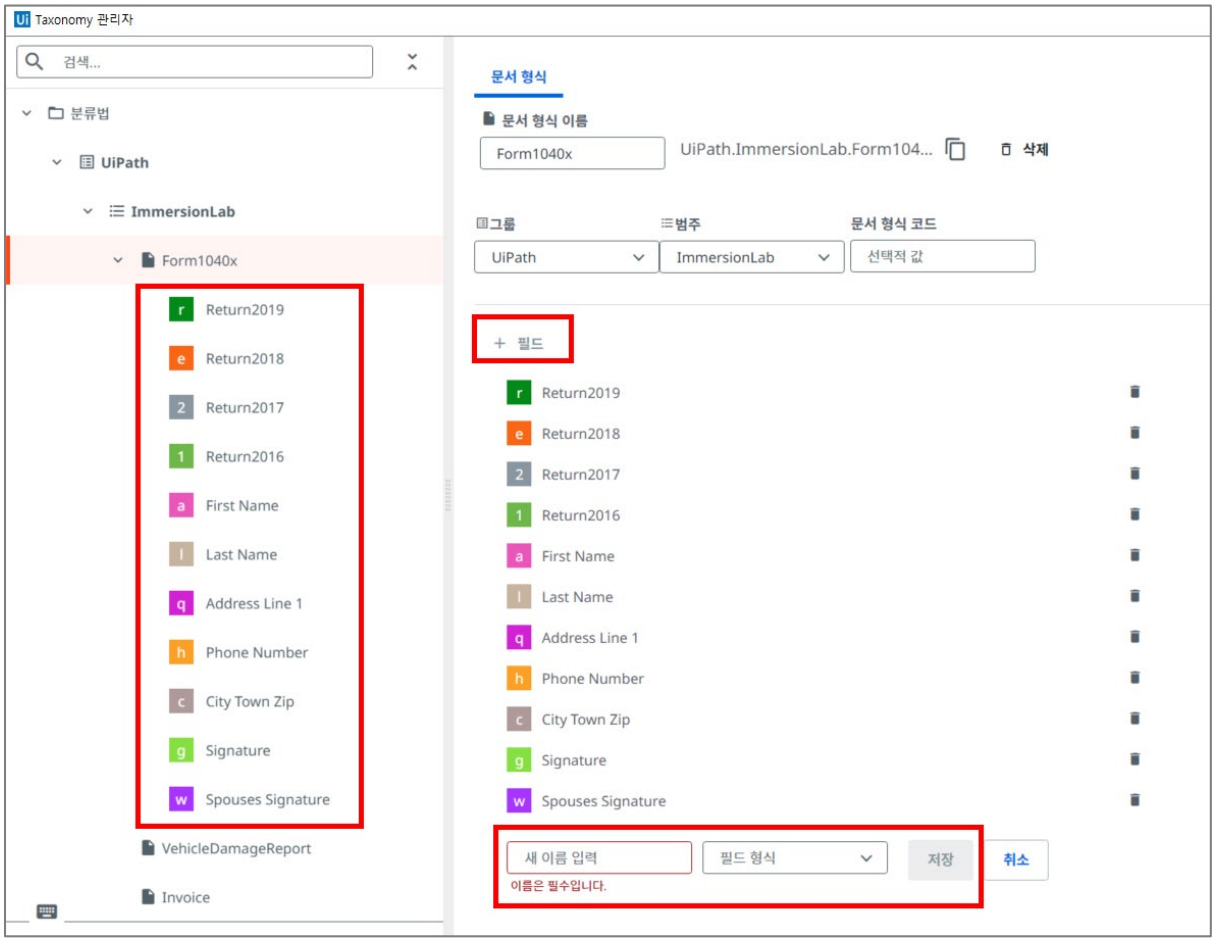


Step5. Form1040x 필드 정의

- 문서 형식은 해당 문서에서 추출하려는 필드(Field)를 정의할 수 있습니다.

- Return2019, Return2018, Return2017, Return2016, Signature, Spouses Signature (Boolean)

- First Name, Last Name, Address Line 1, Phone Number, City Town Zip (Text)

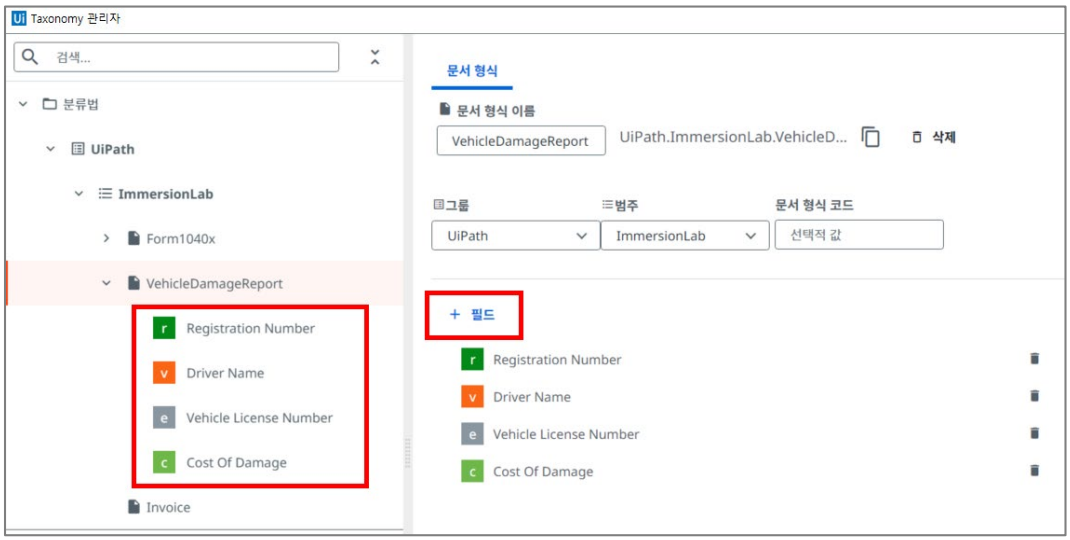


Step6. Vehicle Damage Report 필드 정의

- 문서 형식은 해당 문서에서 추출하려는 필드(Field)를 정의할 수 있습니다.

- Registration Number, Vehicle License Number, Cost Of Damage (Text)

- Driver Name (Name)

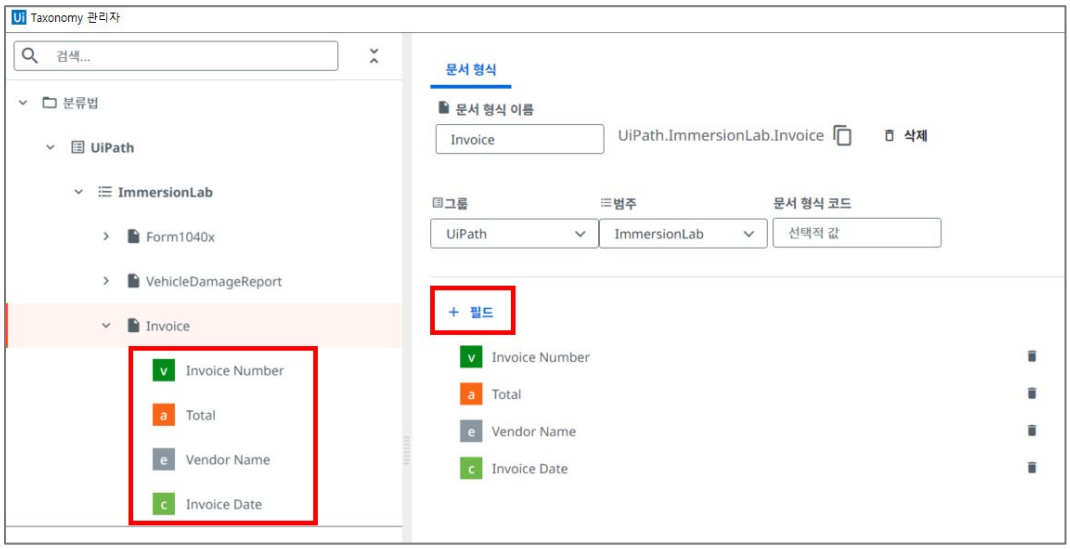


Step7. Invoice 필드 정의

- 문서 형식은 해당 문서에서 추출하려는 필드(Field)를 정의할 수 있습니다.

- Invoice Number, Total, Vendor Name (Text)

- Invoice Date (Date)



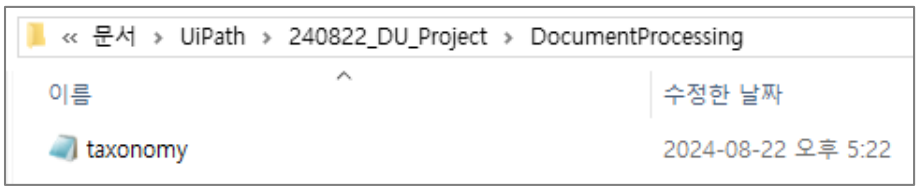
Step8. 최종 확인 후 Taxonomy 관리자 창 닫기

2. UiPath Studio 프로세스 개발 (Rule-Based)_정형

2.1. 초기 세팅

2.1.1. Toxonomy 관리자에서 생성한 파일 위치 확인

Step1. 파일 경로 : DocumentProcessing\taxonomy.json

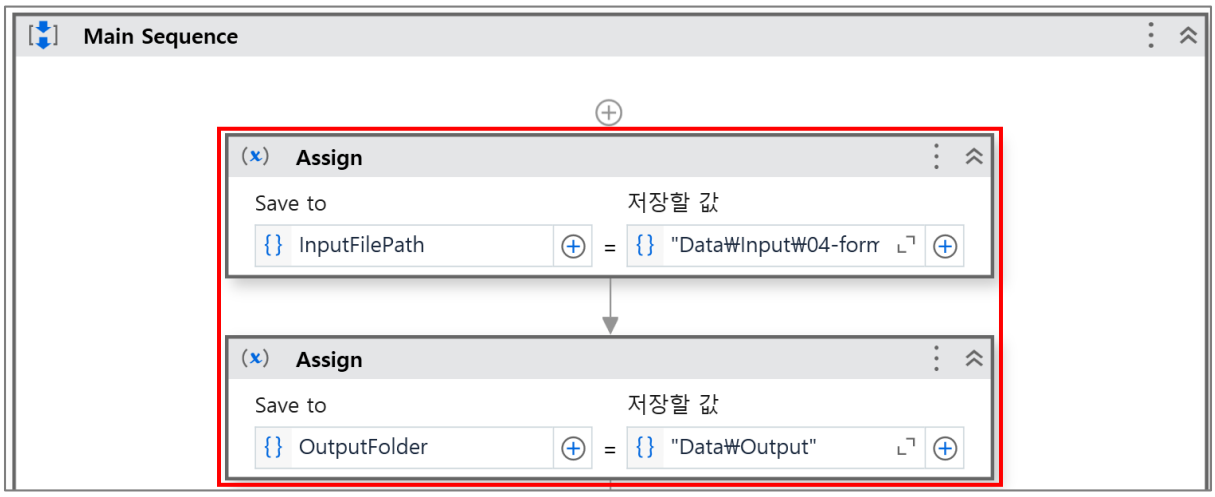


Step2. 작성했던 필드 내용 확인 가능

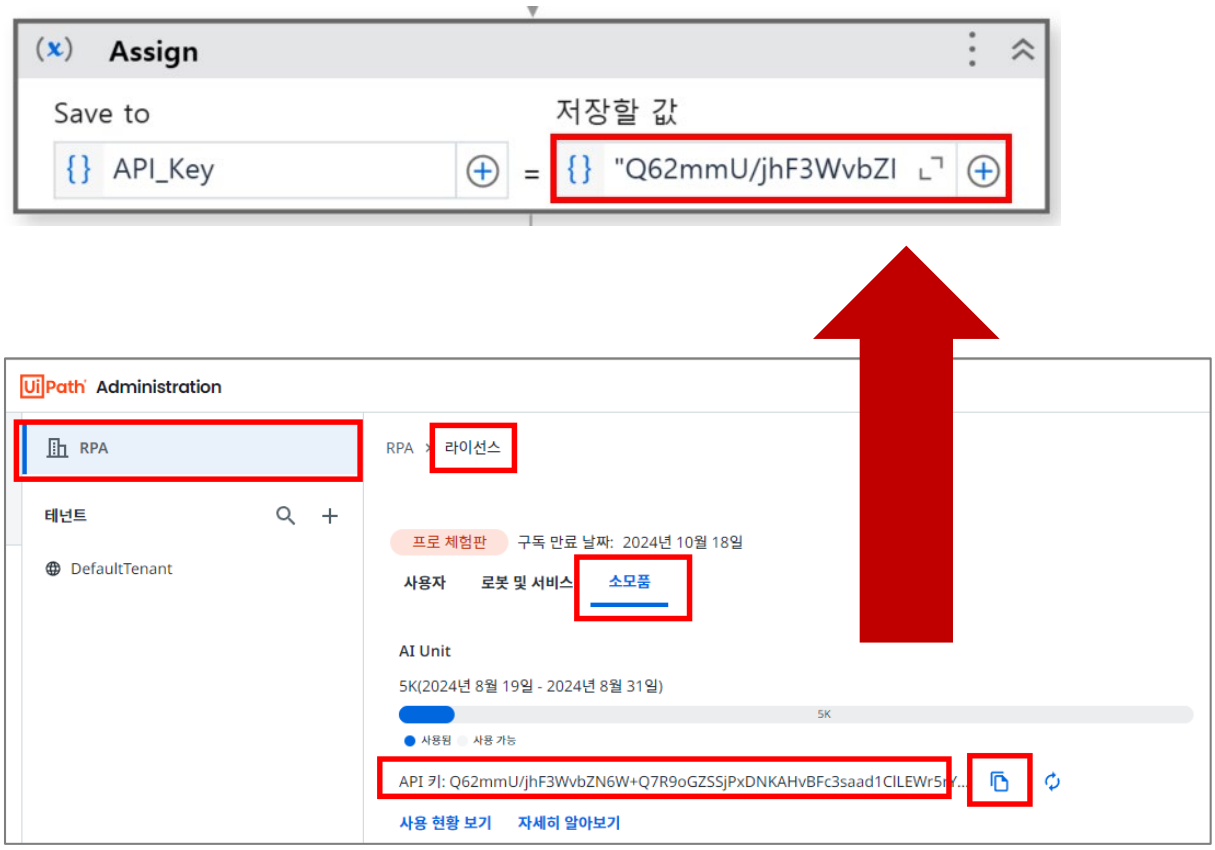

```
{
 "DataContractVersion": "1.1",
 "DocumentTypes": [
  {
   "Connections": [],
   "DocumentTypeId": "UiPath.ImmersionLab.Form1040x",
   "Group": "UiPath",
   "Category": "ImmersionLab",
   "Name": "Form1040x",
   "OptionalUniqueIdentifier": "",
   "TypeField": {
    "FieldId": "UiPath.ImmersionLab.Form1040x.DocumentType",
    "FieldName": "Document Type"
   },
```


2.1.2. 변수 세팅

Step1. 문서 경로 변수 지정



Step2. AI Unit API 키 값 저장 변수 지정



2.2. Load taxonomy

Step1. Load Taxonomy 액티비티 드래그 앤 드롭

- 분류 기준 변수로 출력: taxonomy



2.3. Digitize

- 주어진 문서를 기계 판독 가능한 텍스트를 추출하는 과정으로 주로 광학 문자 인식 (OCR) 기술을 사용하여 진행합니다.

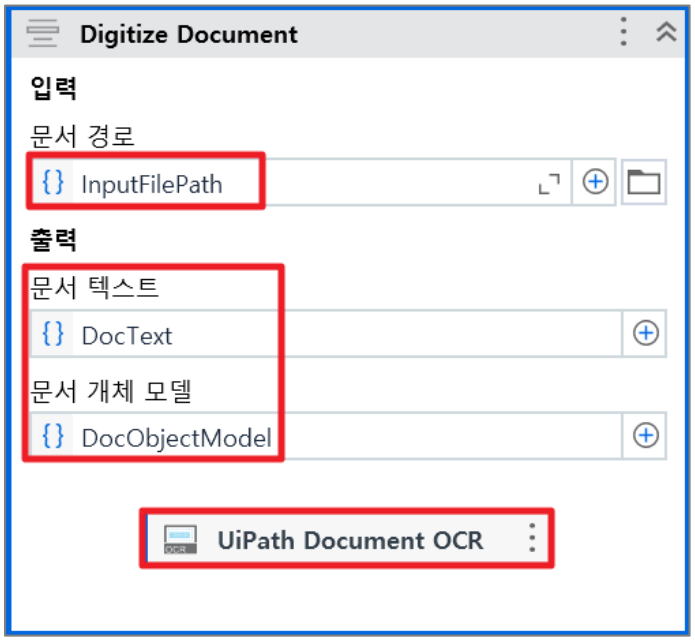
- 기본적으로 많이 활용되고 있는 OCR 엔진

Engine	Print	Handwriting	Checkboxes	Signature	Barcode	Languages
UiPath Document OCR Cloud	✔	✔	✔	✔	✔	Print: Latin based Handwriting (EN, FR, DE)
UiPath Document OCR LocalServer	✔	✔	✔	✔	✔	Print: Latin based Handwriting (EN, FR, DE)
UiPath Chinese-Japanese-Korean OCR	✔	✔	✘	✘	✘	Chinese Japanese Korean
Kofax Omnipage activity packages	✔	✘	✘	✘	✘	https://docs.uipath.com/activities/docs/omnipage-ocr(opens in a new tab)
Google Cloud Vision OCR	✔	✔	✘	✘	✘	https://cloud.google.com/vision/docs/languages(opens in a new tab)
Microsoft Azure Computer Vision Read OCR	✔	✔	✘	✘	✘	https://learn.microsoft.com/en-us/azure/cognitive-services/computer-vision/language-support(opens in a new tab)

Step1. Digitize Document 액티비티 드래그 앤 드롭

- 문서 경로: InputFilePath

- 문서 텍스트, 문서 개체 모델(문서 요소들의 다양한 구성 요소(ex: 좌표 값)) 변수로 출력



Step2. 'UiPath Document OCR' 액티비티 API 키, 엔드포인트 값 입력

- API 키: API_Key

- 엔드포인트: https://du.uipath.com/ocr

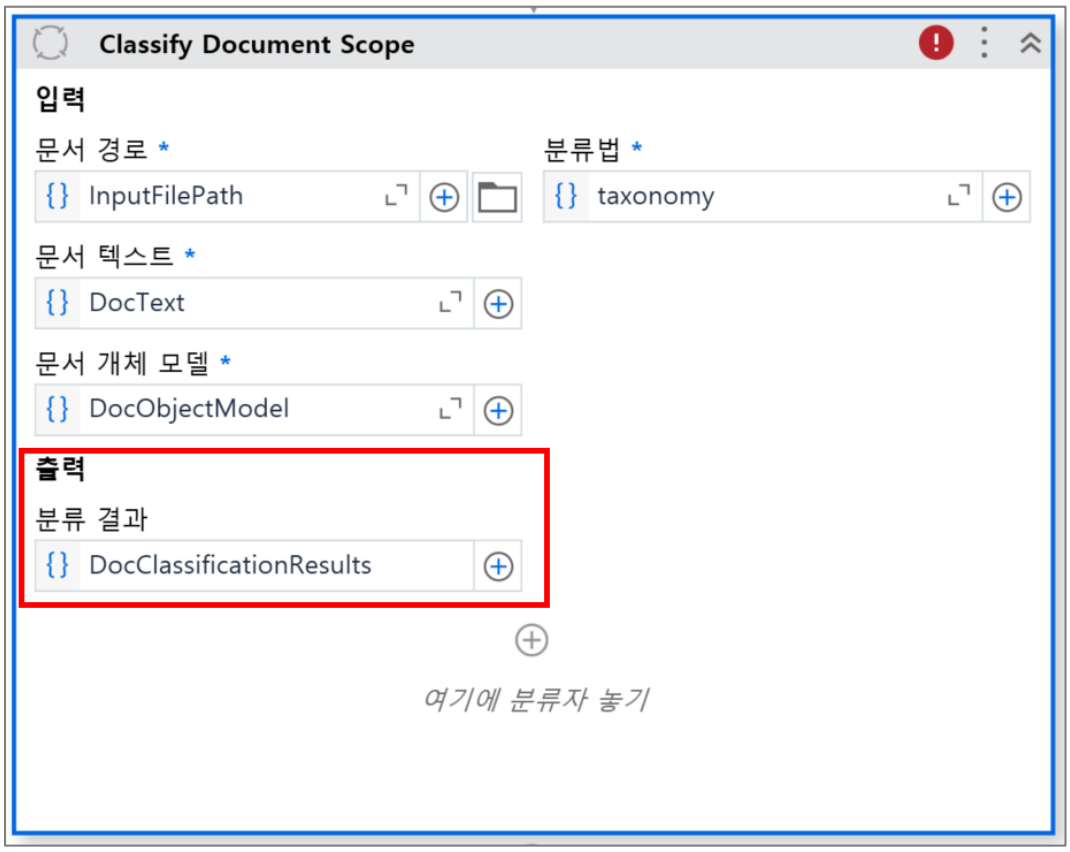


2.4. Classify

- 파일을 문서 유형별로 분류하고 분할합니다.

Step1. Classify Document Scope 액티비티 드래그 앤 드롭

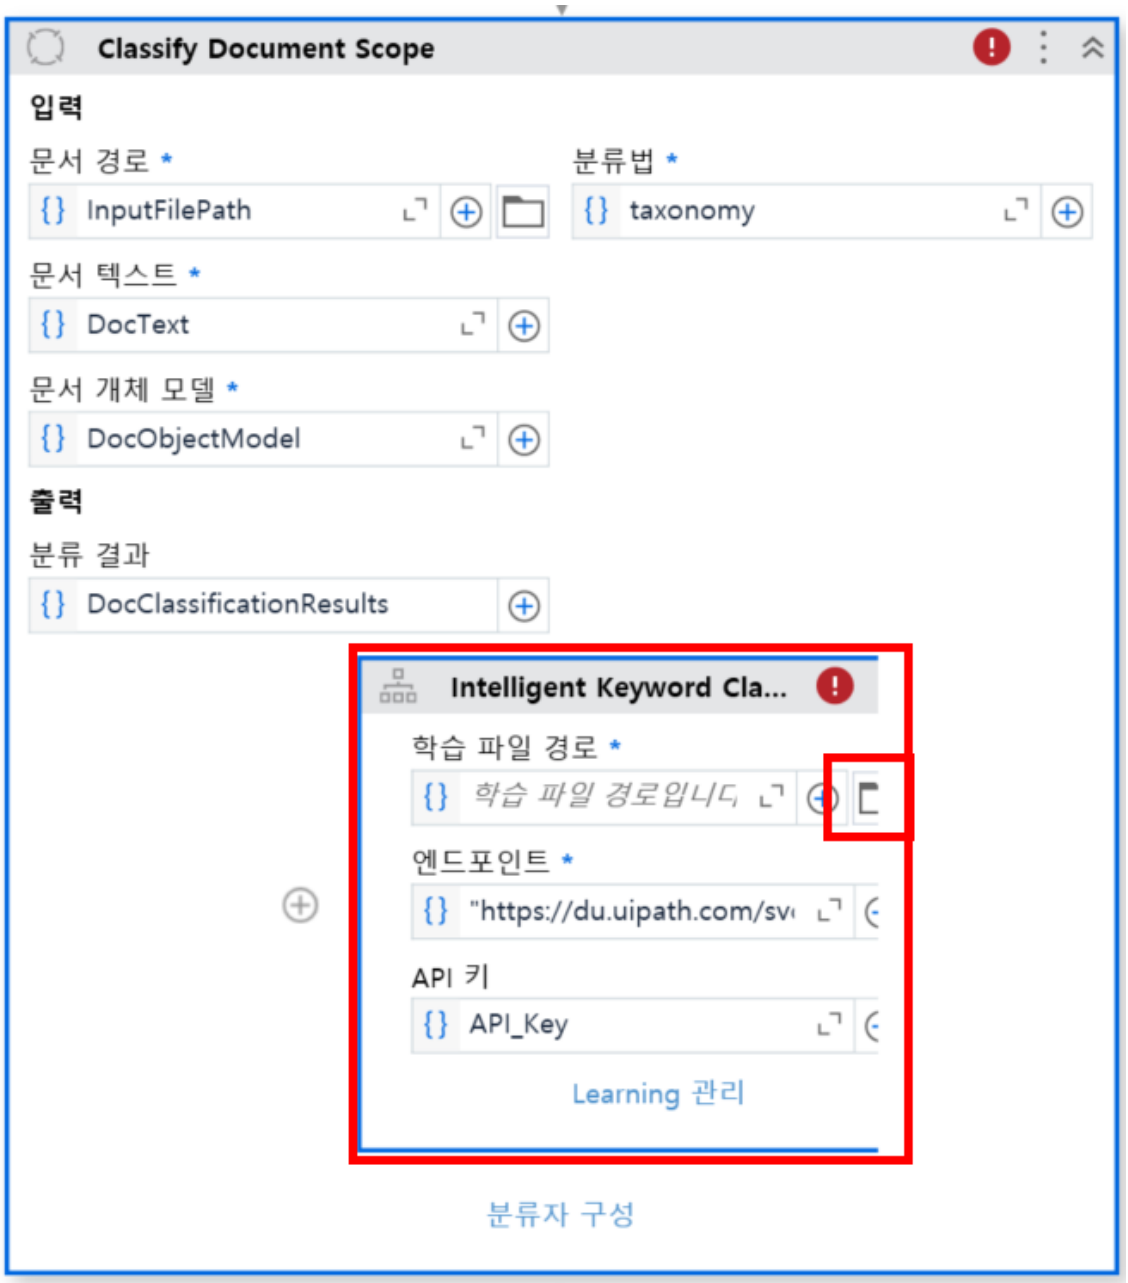
- 분류 결과 변수 생성: DocClassificationResults



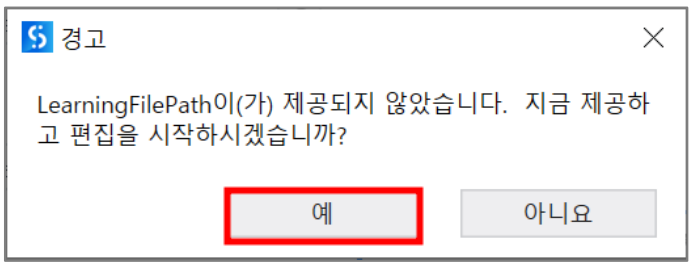
Step2. 분류자 설정

Keyword Based Classifier	- 키워드 기반 알고리즘을 사용해 문서를 분류 - 일반적으로 문서의 제목을 입력해 분류하는 방식으로 활용
Intelligent Keyword Classifier	- 특정 문서 유형의 파일에서 학습한 단어 벡터로 문서를 분류 - 파일에 여러 유형이 포함되어 있어 분할이 필요할 경우 활용
Machine Learning Classifier	- AI Center 에서 미리 정의한 모델을 사용해 문서를 분류

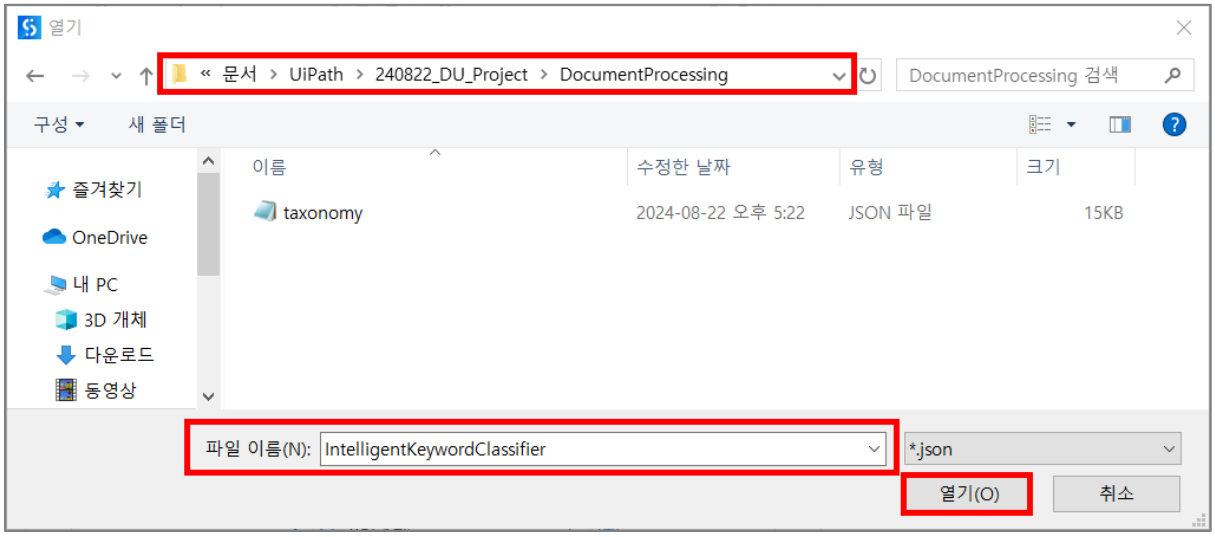
- Intelligent Keyword Classifier 액티비티 드래그 앤 드롭 후 파일 탐색 버튼 클릭



- 해당 창이 나오는 경우 '예' 클릭



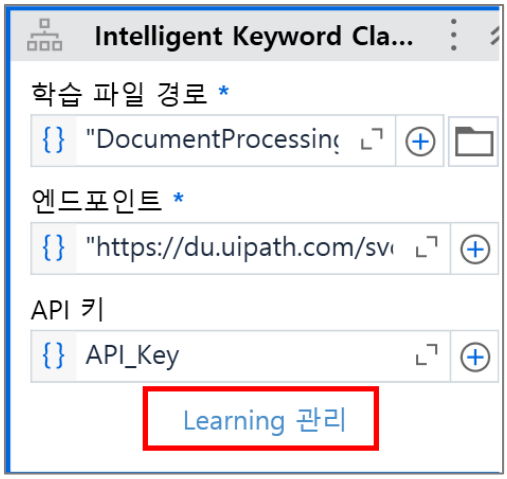
- 파일 이름에 IntelligentKeywordClassifier 입력 후 열기 클릭 (자동으로 파일 생성)



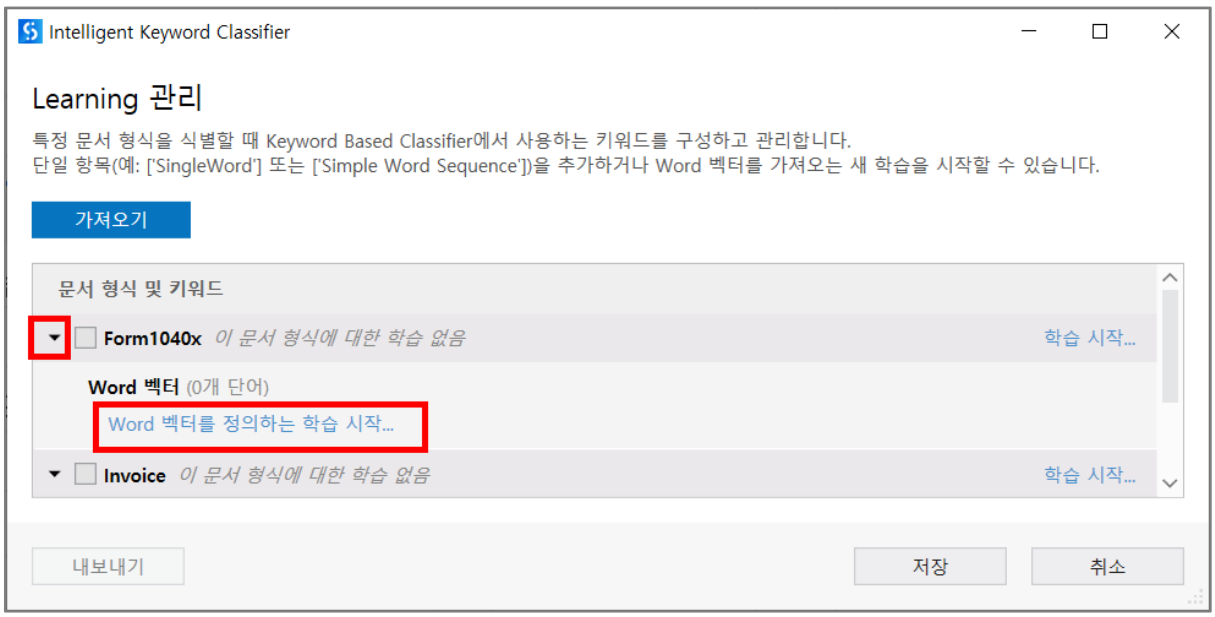
Step3. 각 항목에 대해 학습 시작 (예시: Invoice)

*** 선택 작업 (뒤에 Validate, Train 작업을 거쳐 학습시킬 수 있기 때문에 생략 가능)**

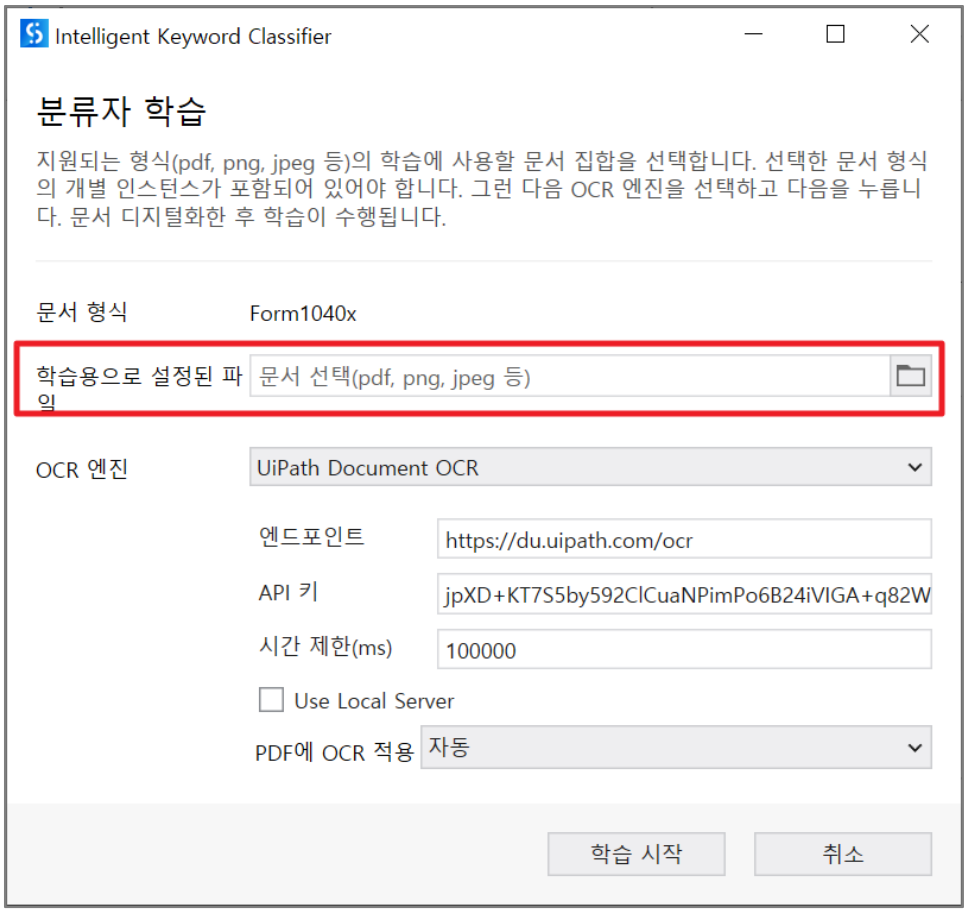
- Learning 관리 클릭



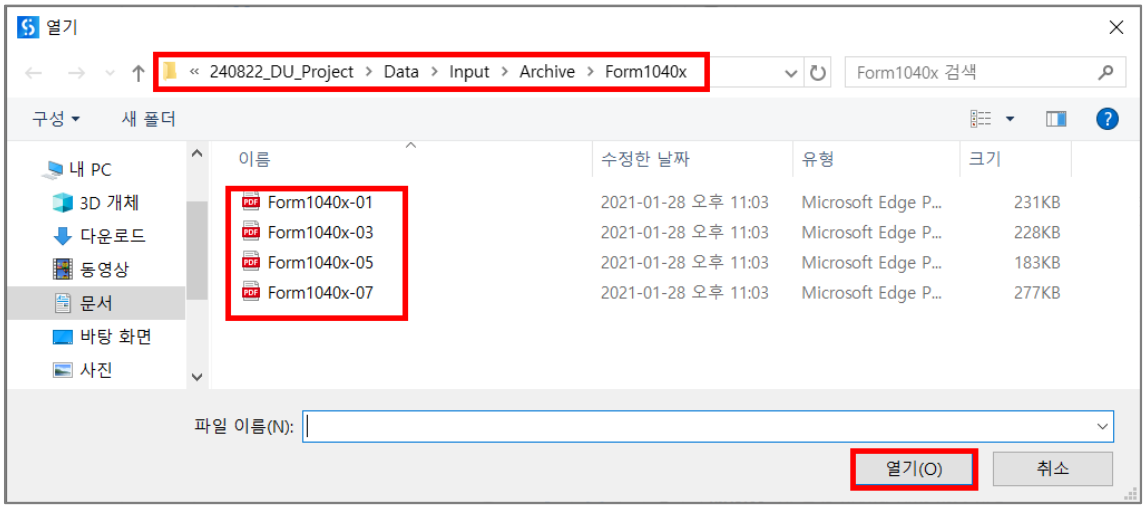
- ‘Word 벡터를 정의하는 학습 시작...’ 클릭



- 학습용으로 설정된 파일 – 파일 열기 클릭



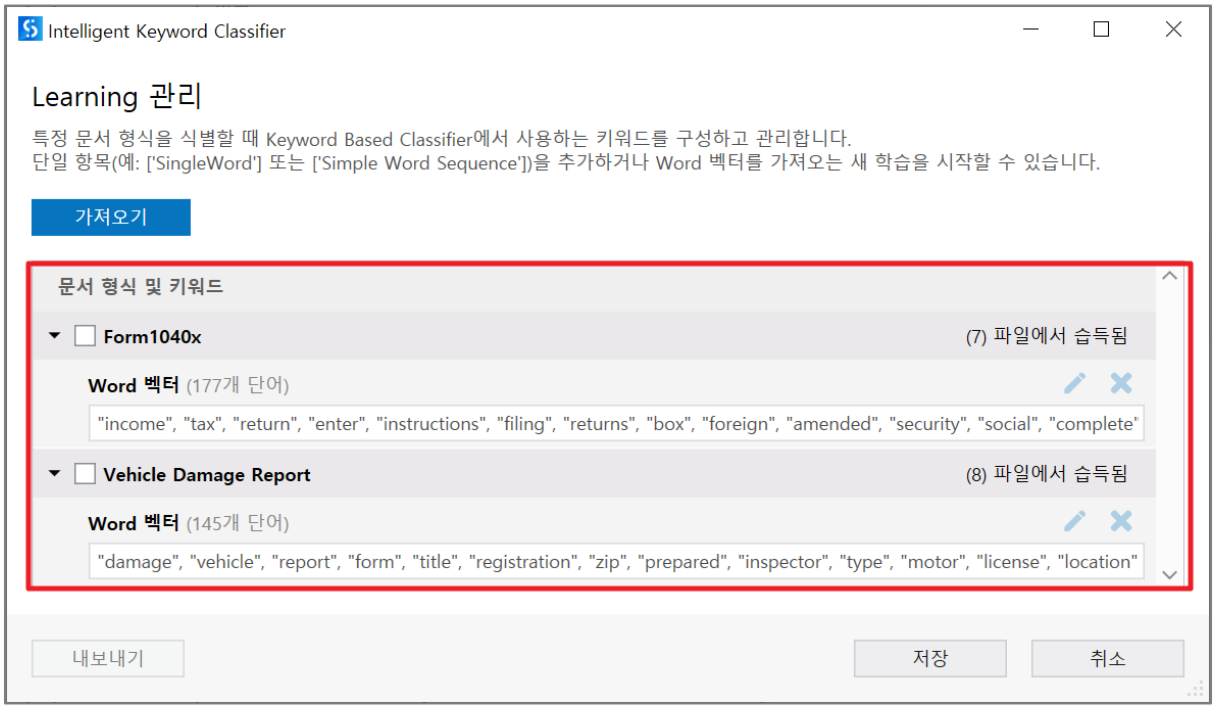
- Data\Input\Archive\Form1040x 내 Form1040x 전체 선택 후 열기 클릭



- 학습 시작 클릭

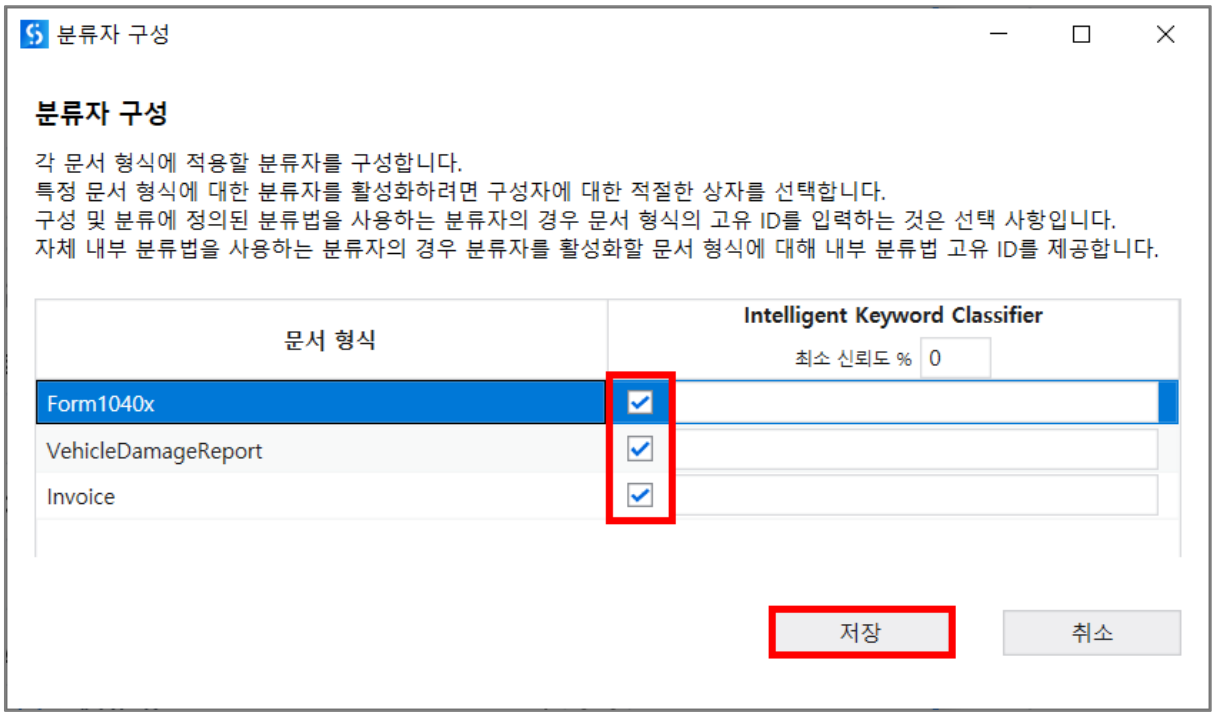


- 결과 확인



Step4. 분류자 구성

- '최소 신뢰도'란 최소로 정한 수치 이하로 떨어지면 그 문서는 실패 처리할 수 있는 기능

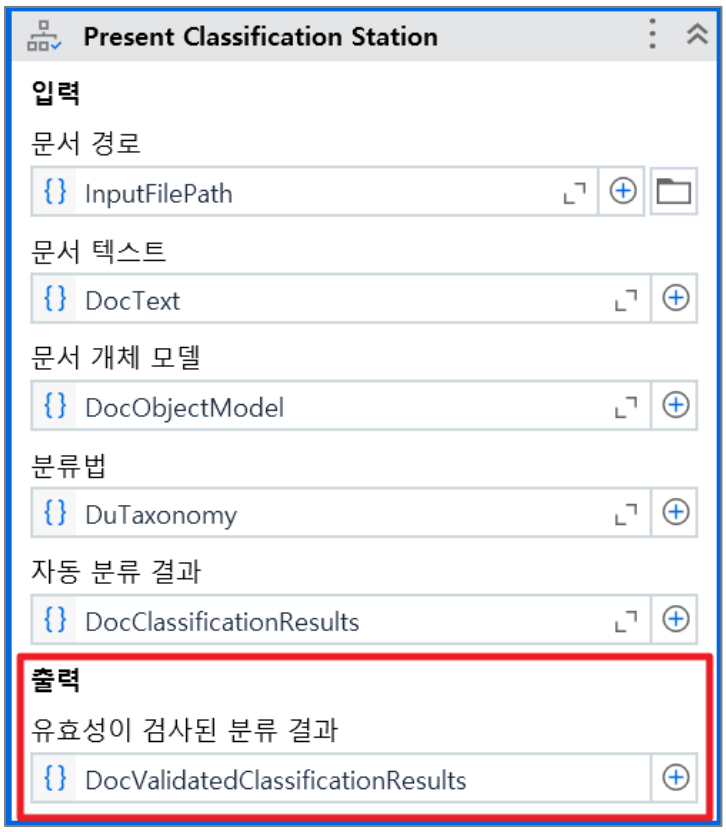


2.5. Vaildate (Classify)

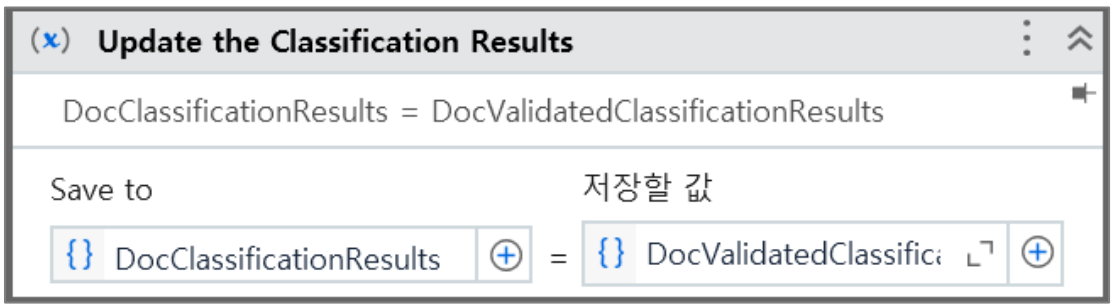
- 분류된 문서를 사람이 검토합니다.

Step1. Present Classification Station 액티비티 드래그 앤 드롭

- 유효성이 검사된 분류 결과 변수 생성: DocValidatedClassificationResults

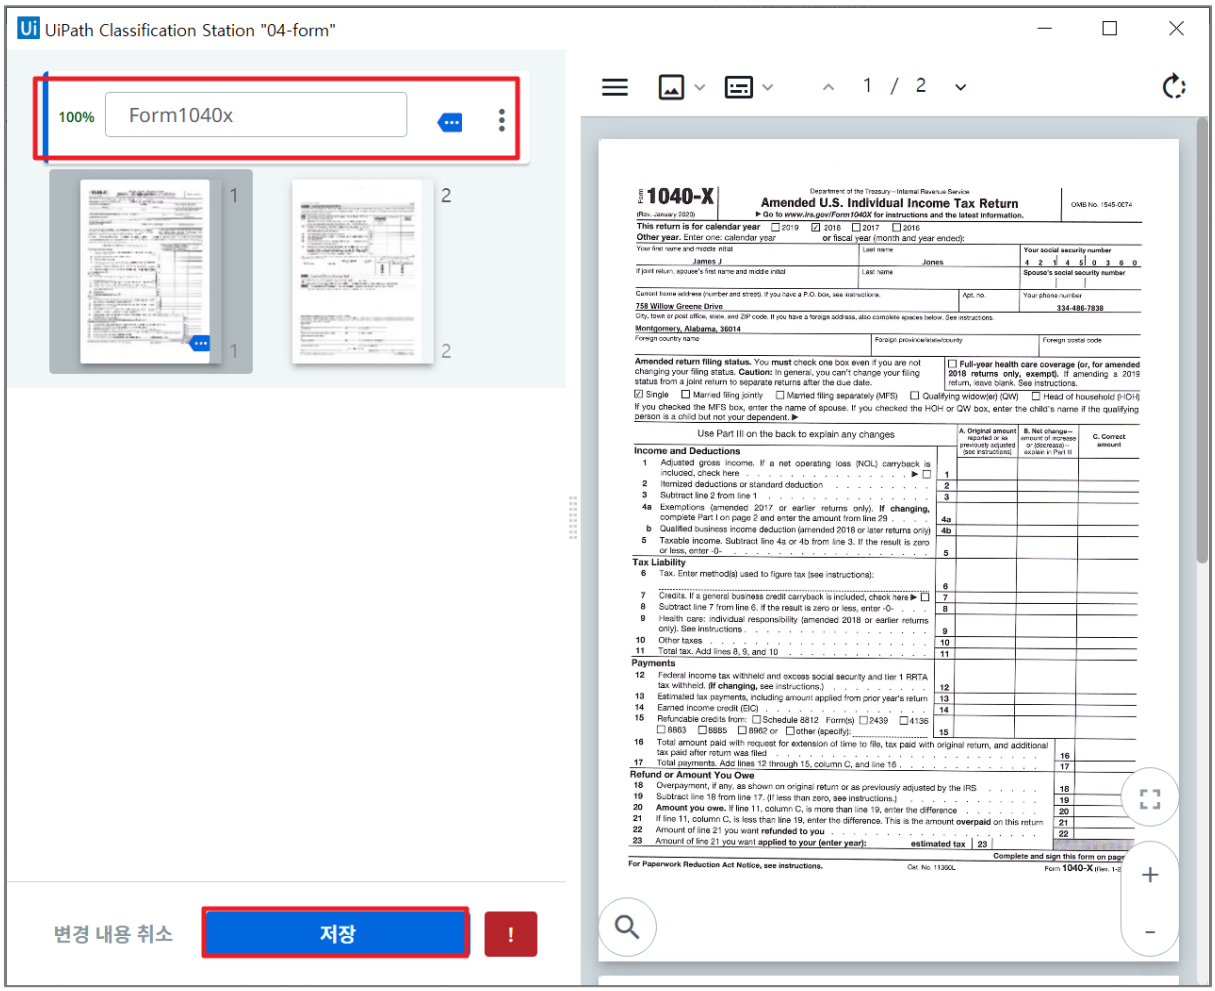


Step2. 사람이 검증한 데이터를 다시 기존의 변수에 저장



Step3. 프로세스 작성 후 테스트 실행

- 분류 결과 확인 후, 저장 버튼 클릭



- 만약 예외인 경우는 예외 버튼 클릭





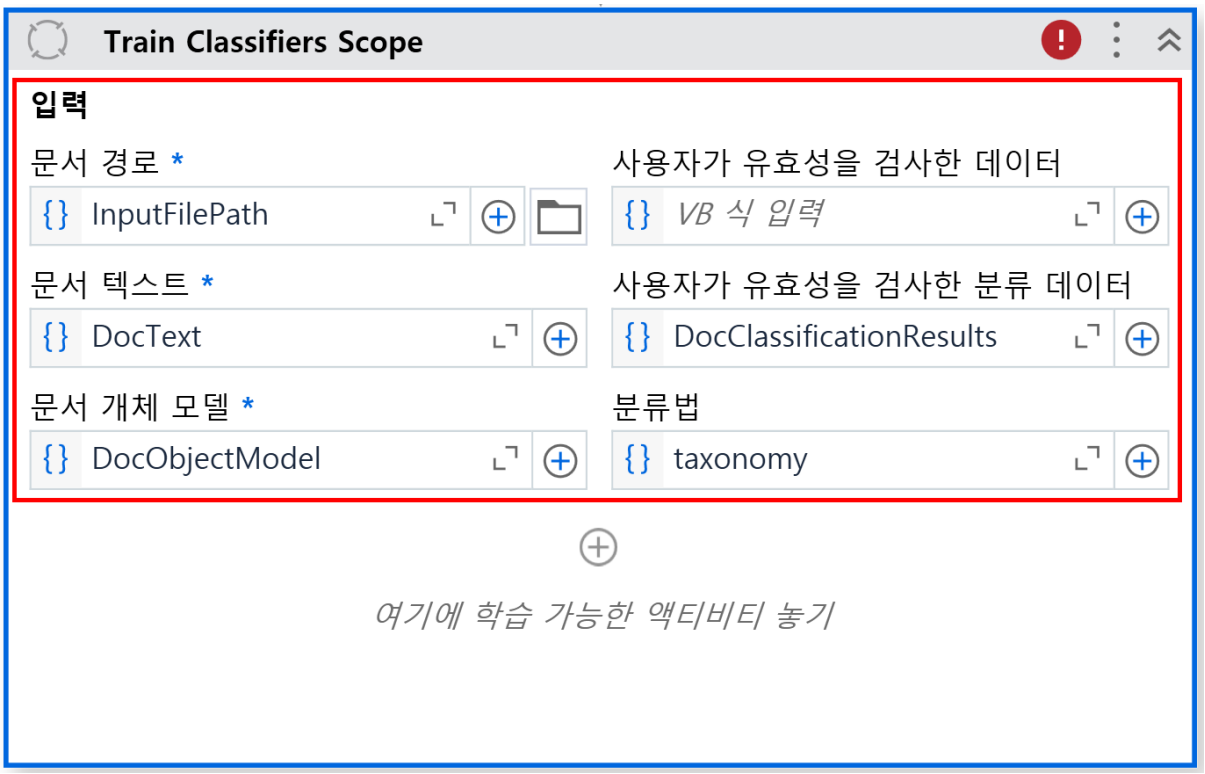
⚠ Present Classification Station: 문서의 유효성을 검사하는 동안 오류가 발생했습니다. 04-form. 이유: 문서 양식 다름

2.6. Train (Classify)

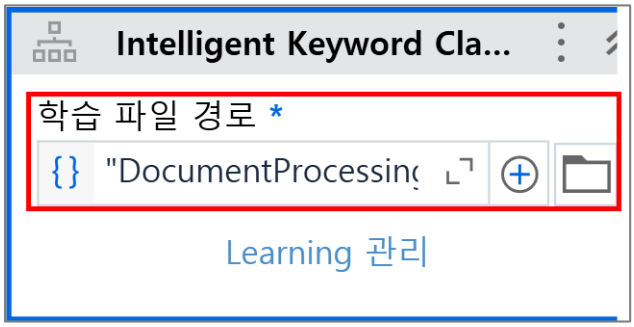
- 검증된 문서를 기반으로 프로세스를 훈련시킵니다

Step1. Train Classifiers Scope 액티비티 드래그 앤 드롭

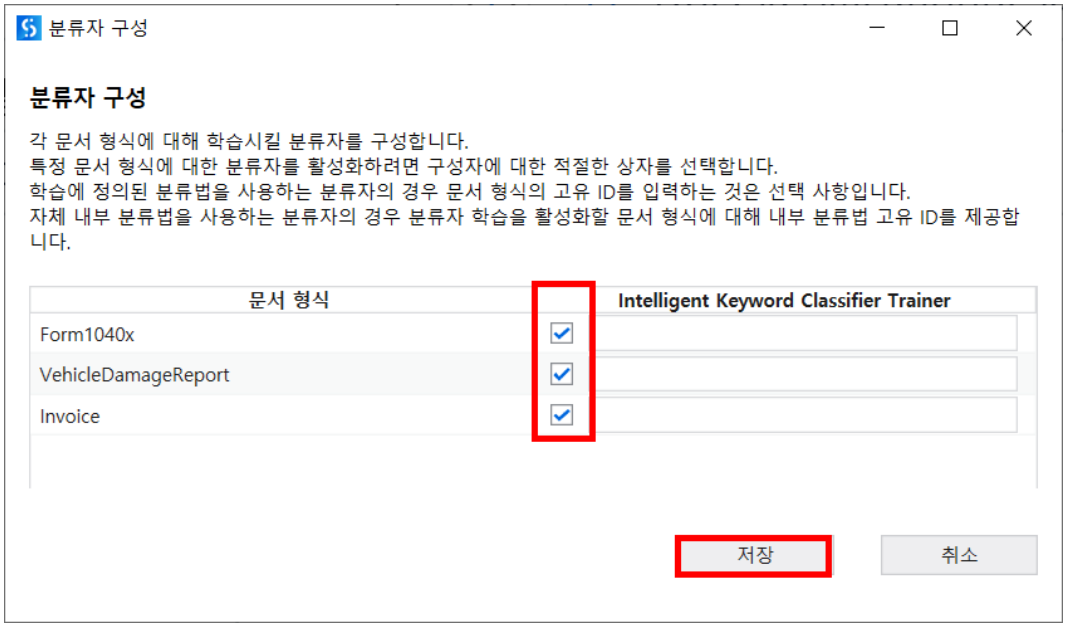
- 입력 내용 작성



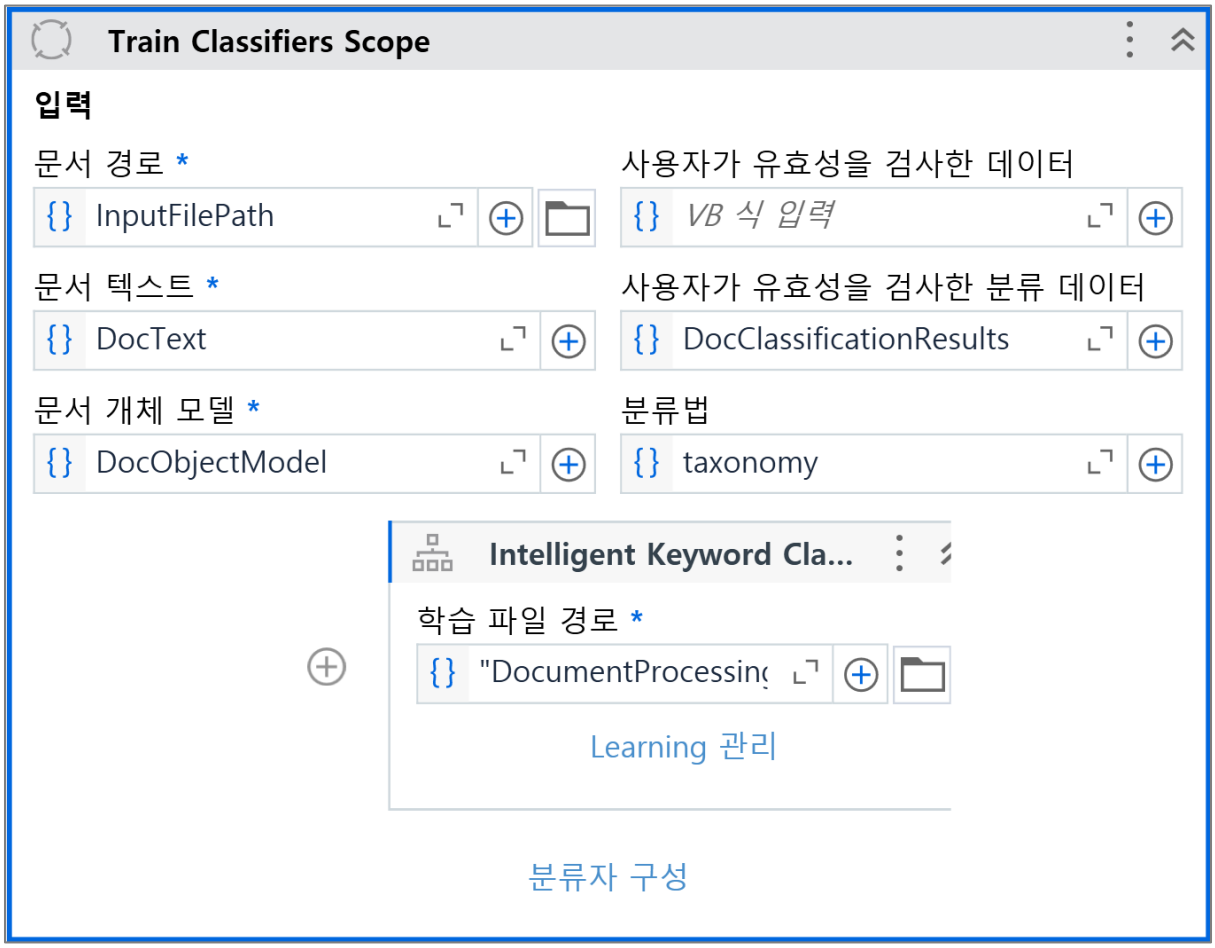
Step2. Intelligent Keyword Classifier Trainer 액티비티 드래그 앤 드롭 후 Intelligent~.Json 파일 불러오기



Step3. 분류자 구성 체크박스 선택



Step4. 결과 확인

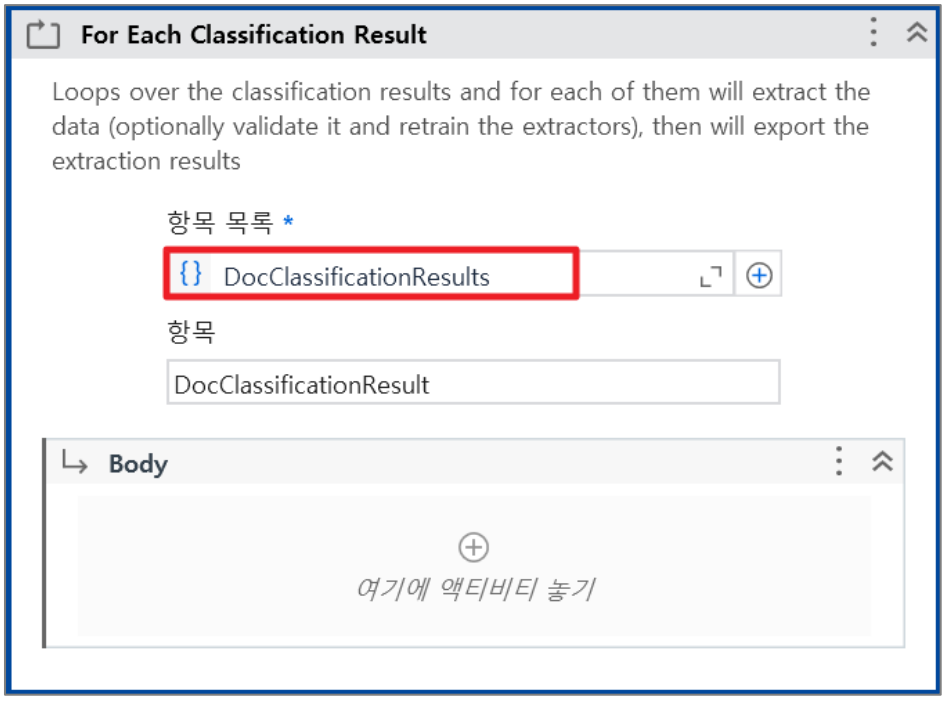


2.7. Extract

- 추출된 데이터를 추가 사용을 위해 내보냅니다

Step1. For Each 액티비티 드래그 앤 드롭

- DocClassificationResults 변수는 배열 변수로 DU 진행 중 문서 분류 결과 데이터 (문서 카테고리, 신뢰도 점수 등)를 저장하고 있습니다. 따라서 문서의 종류가 다양하다면, 반복문을 통해 문서 카테고리 별로 추출 작업을 진행해야 하기 때문에 For Each 액티비티를 활용해 개발합니다.

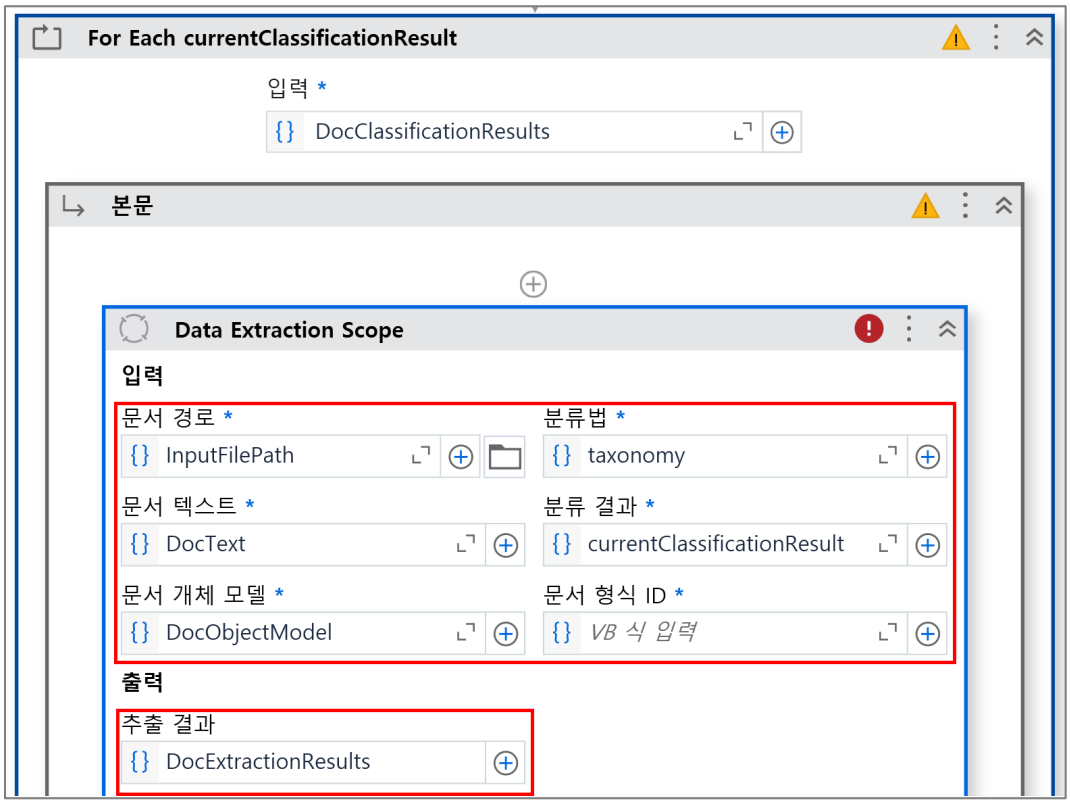


- 여러 개의 문서가 합쳐진 파일의 경우 문서들에 대해 몇 번째 문서인지 확인하기 위해 For Each 내 인덱스 변수 생성



Step2. Data Extraction Scope 액티비티 드래그 앤 드롭

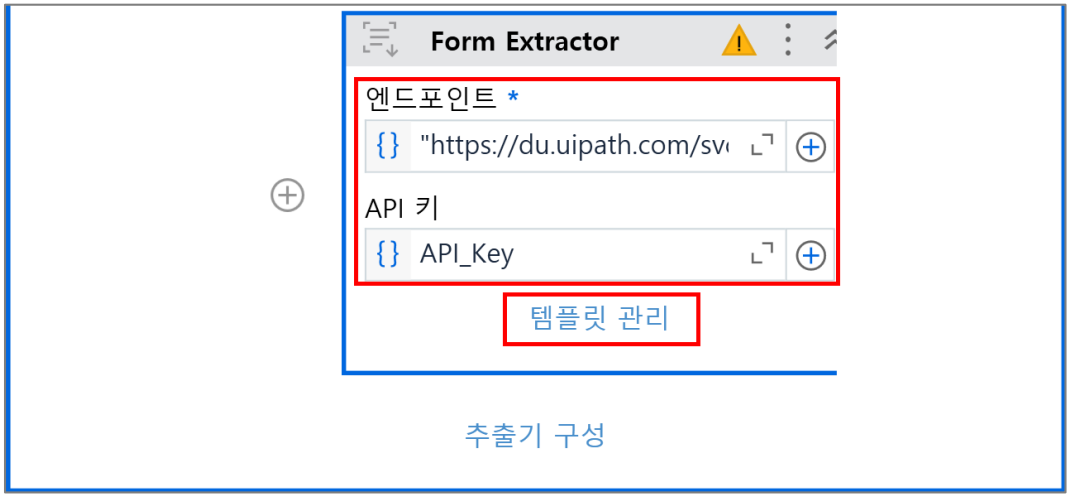
- 추출 결과: Extraction_Result 변수 생성



Step3. Form Extractor 액티비티 드래그 앤 드롭

- Form Extractor: 다양한 유형의 문서에 대해 일반화된 방법을 제공하여 특정 양식에 맞추어 규칙을 정의하지 않고도 데이터를 추출하는 방법

- 엔드포인트: https://du.uipath.com/svc/formextractor - API 키: API_Key



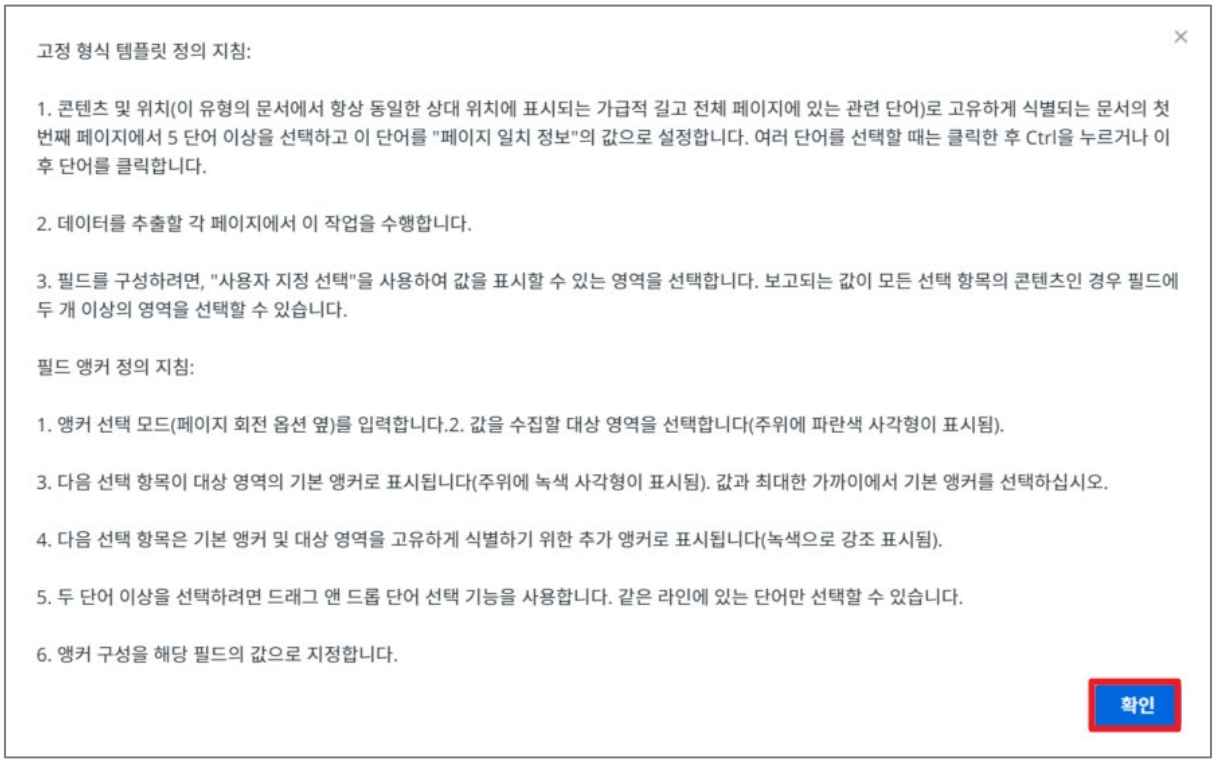
Step4. 템플릿 관리 클릭 후 템플릿 만들기 버튼 클릭



- 템플릿 양식 작성 후 구성 버튼 클릭



- 확인 버튼 클릭

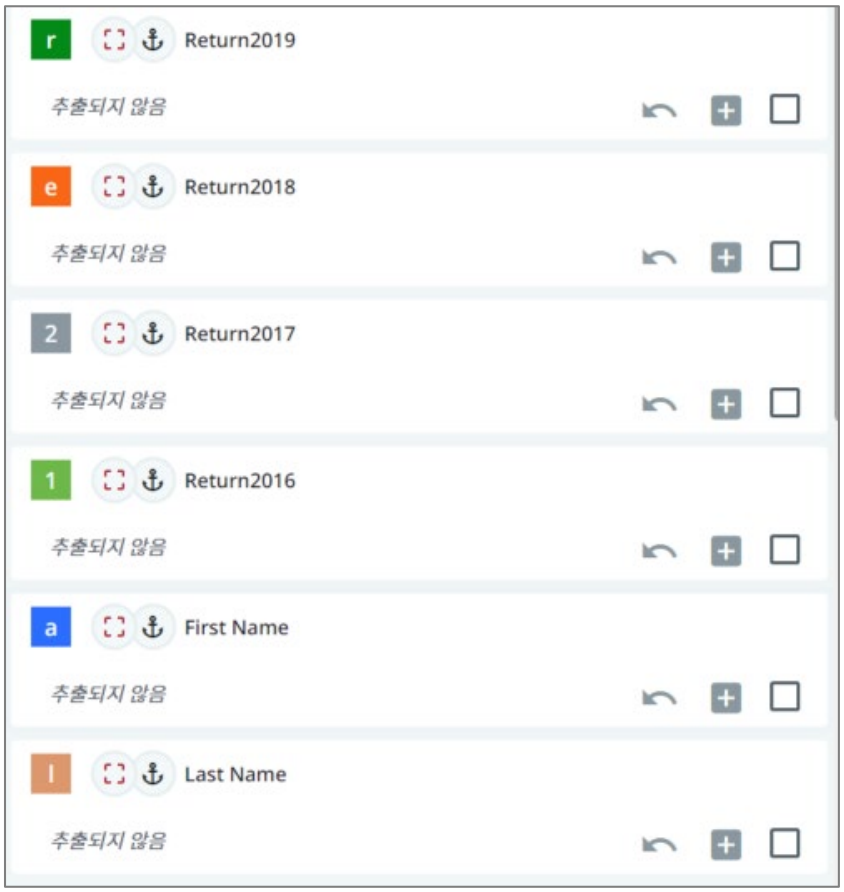


Step5. Template Manager 작성

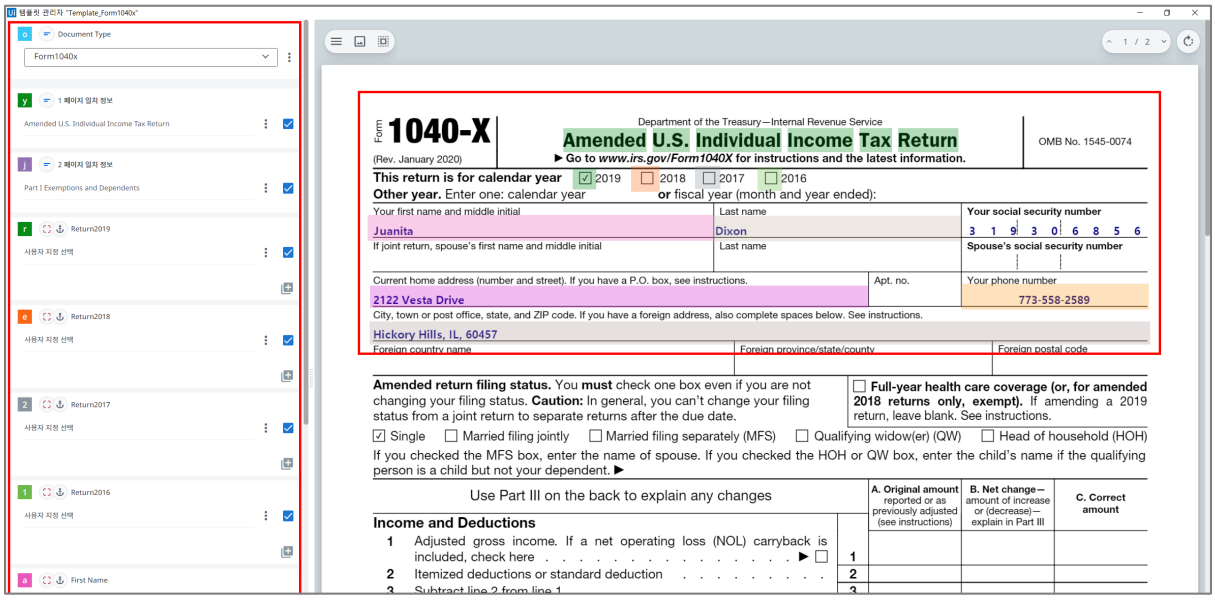
- 토큰(Token): 각 페이지를 **구분할 수 있는 고유 구분자 (Ctrl 키를 누른 상태로 데이터 클릭)**



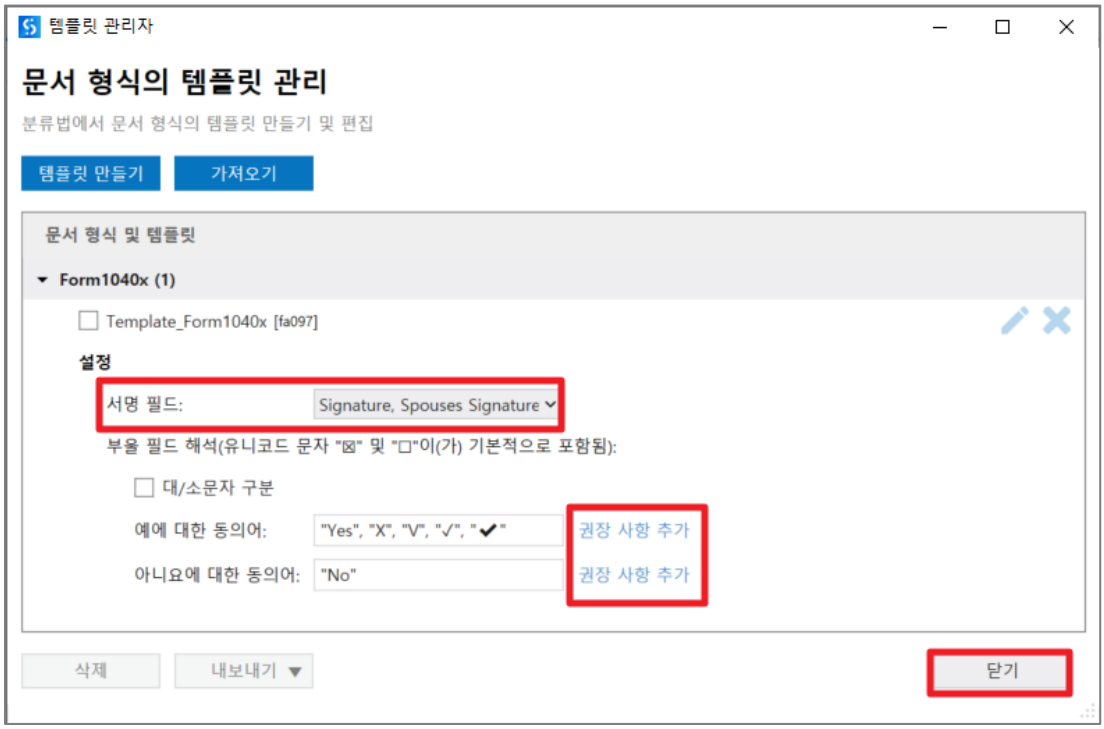
- 사용자 지정 영역(Custom Area): 특정 데이터가 나타나길 원하는 영역 (클릭이 아닌 영역 드래그 후 '사용자 지정 영역' 클릭)



- 영역 모두 선택 후 제출 버튼 클릭

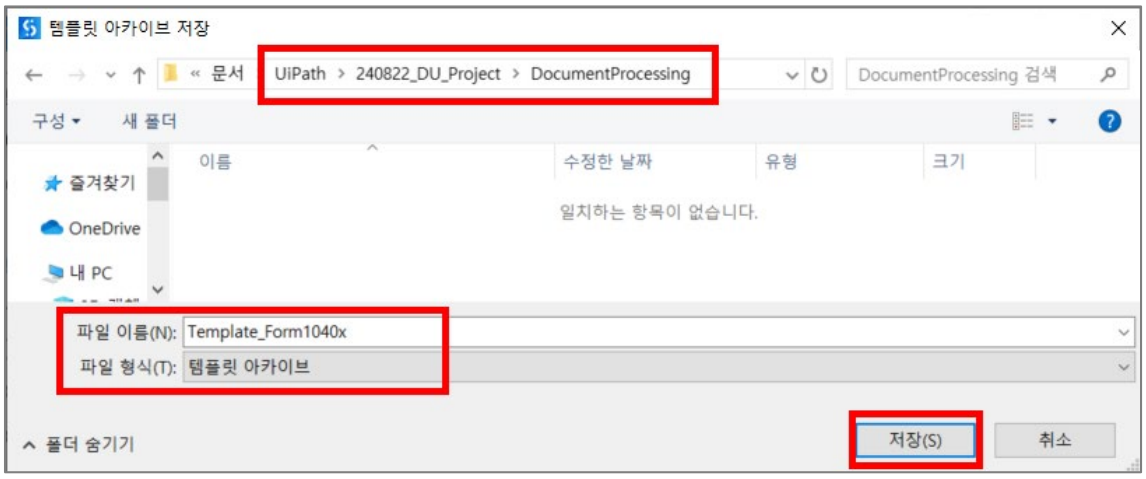


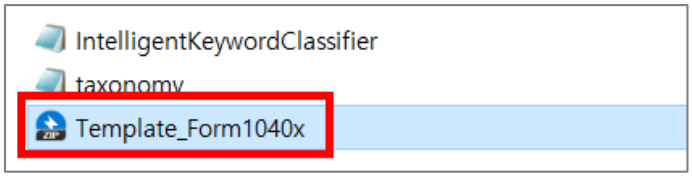
Step6. Form Extractor 설정 후 닫기 버튼 클릭



**** 템플릿 내보내기를 하면 나중에 재설정을 하지 않고, 가져오기를 진행할 수 있음.****







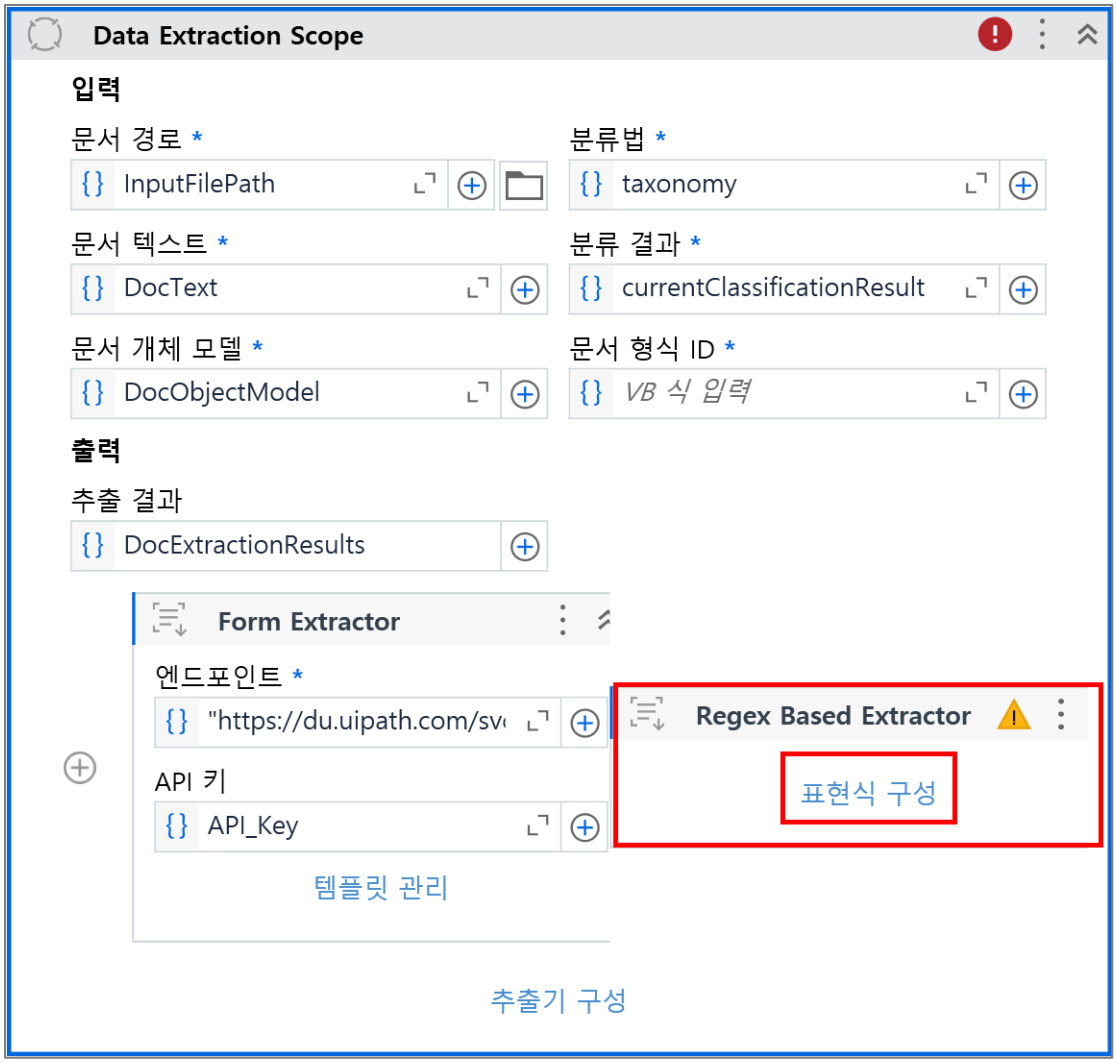
Step7. Regex Based Extractor 액티비티 드래그 앤 드롭

- **Regex Based Extractor**: 다양한 유형의 문서에 대해 **정규식**을 이용하여 데이터를 추출하는 방법

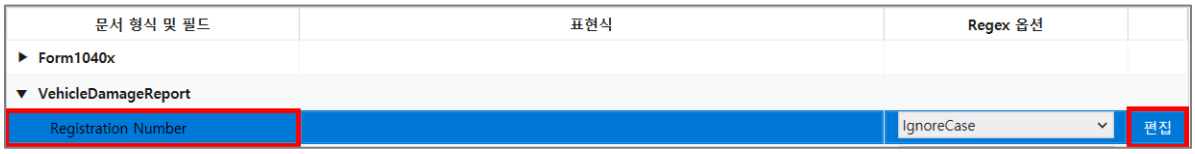
- **정규식(정규 표현식, Regular Expression)이란?**

: 문자열에서 특정 패턴을 찾거나 대체하거나 추출하기 위해 사용하는 강력한 도구입니다. 프로그래밍 언어나 텍스트 편집기에서 자주 사용됩니다. 정규식은 문자와 기호로 이루어진 패턴을 정의하며, 이 패턴을 기반으로 문자열을 검색합니다. 예를 들어, 이메일 주소나 전화번호와 같은 특정 형식의 문자열을 검증하거나 추출할 때 유용합니다.

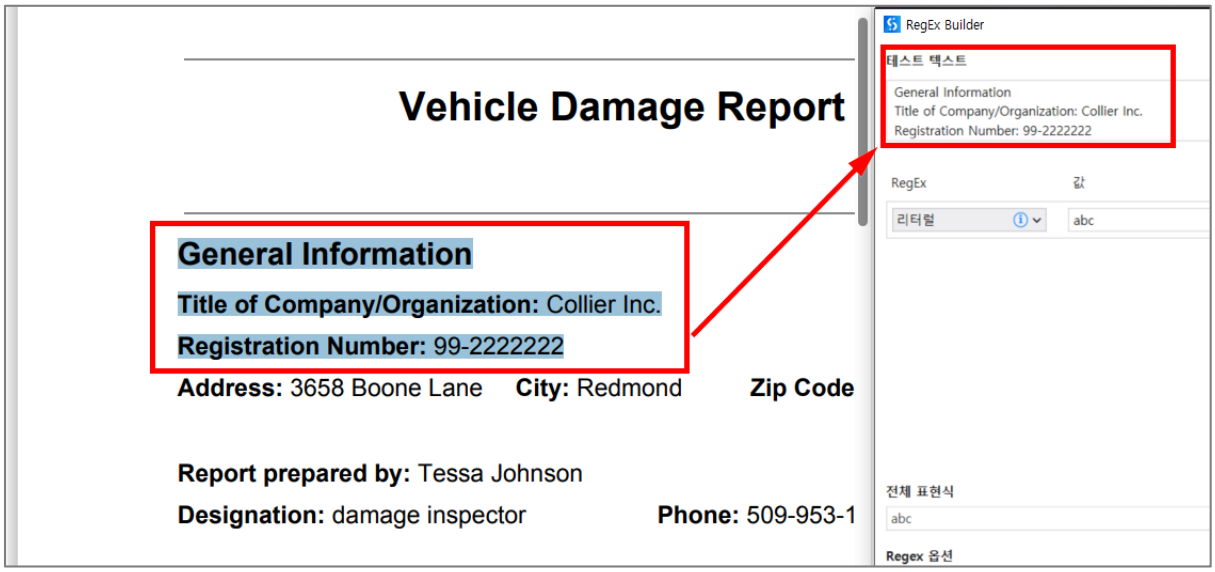
- 표현식 구성 클릭



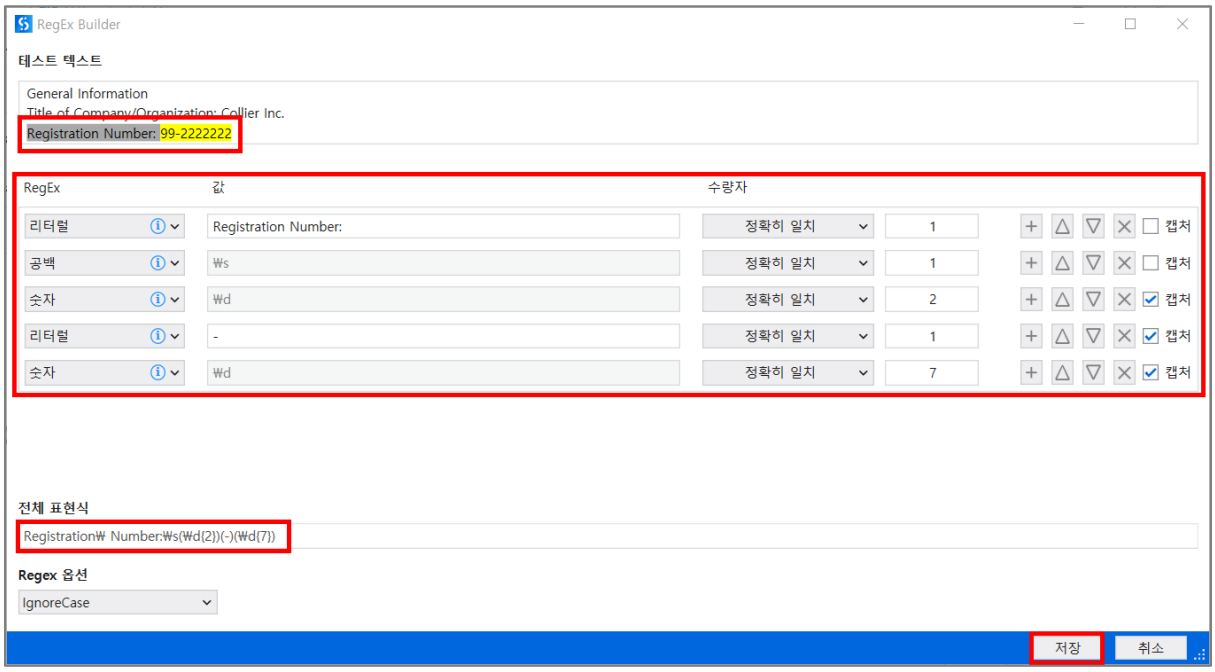
- 편집 클릭 후, 정규 표현식 작성



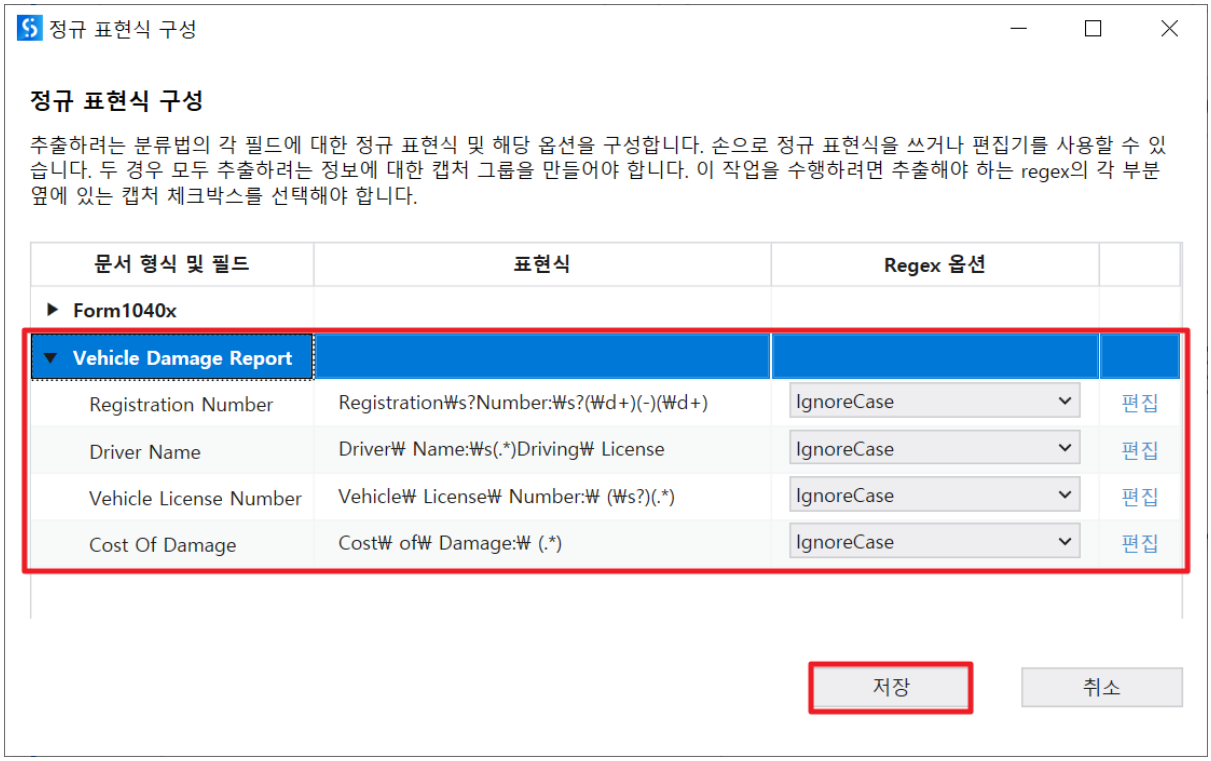
Step8. 테스트 텍스트 드래그 후, 복사 및 붙여넣기 (예시: Registration Number)



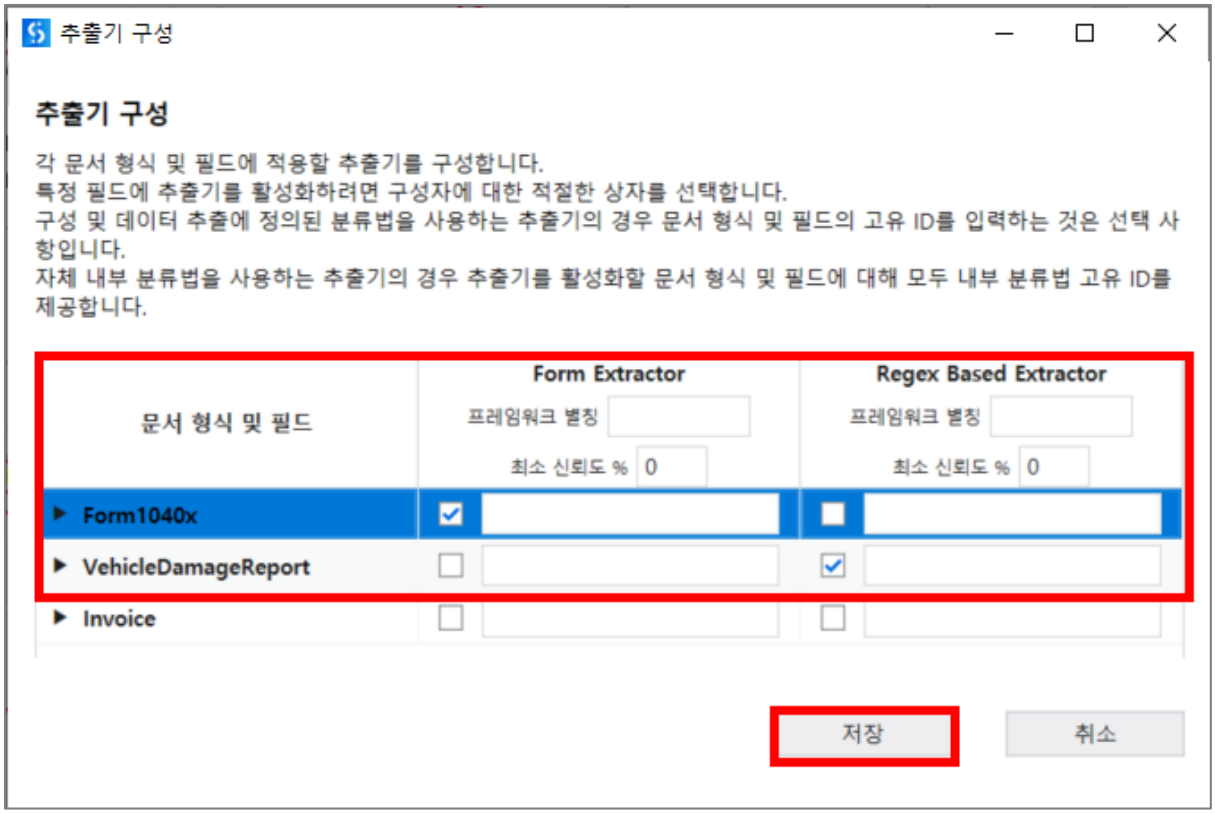
Step9. Regex 표현식 선택



Step10. 이후 나머지 항목들도 정규 표현식 작성 후 저장 버튼 클릭



Step11. 추출기 구성 작성 후 저장 버튼 클릭

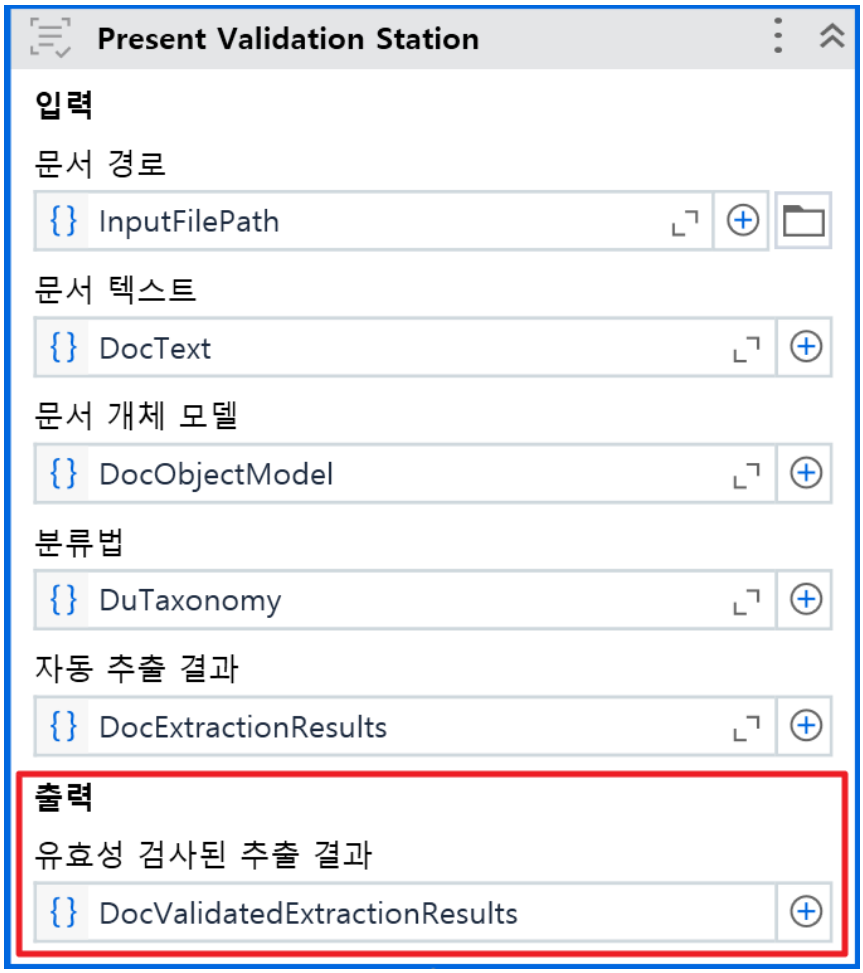


2.8. Vaildate (Extract)

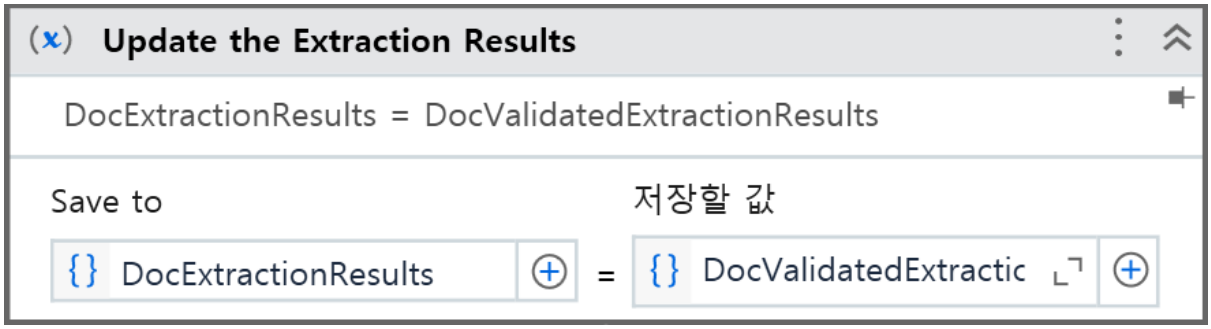
- DU 로 추출된 데이터가 정확한지 사람이 검증

Step1. Present Validation Station 액티비티 드래그 앤 드롭

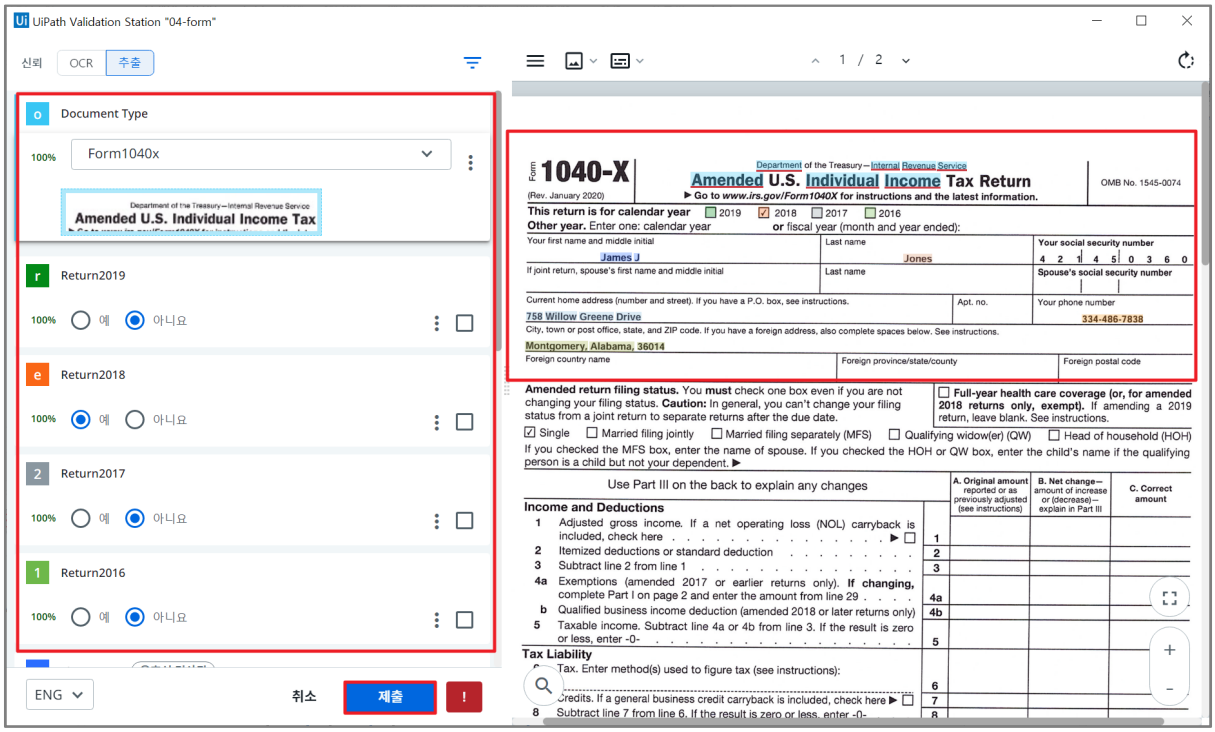
- 유효성 검사된 추출 결과: DocValidatedExtractionResults



Step2. 사람이 검증한 데이터를 다시 기존의 변수에 저장



Step2. 실행 후 테스트 결과 확인



2.9. Train (Extract)

- DU 로 추출한 데이터로 ML 스킬 재학습을 진행해야 하지만 현재 단계는 Rule-Based 단계이므로 생략하고 진행함.(3.4. 에서 진행)

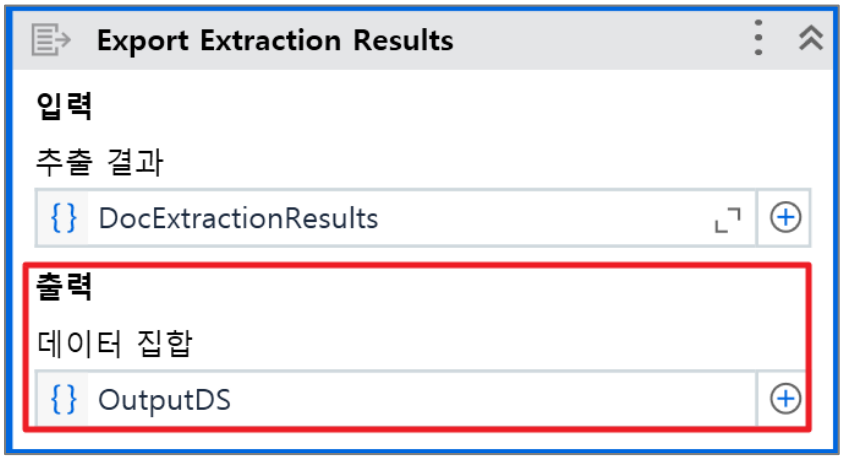
2.10. Export

- 추출된 데이터를 추가 사용을 위해 내보냅니다.

Step1. Export Extraction Results 액티비티 드래그 앤 드롭

- 데이터 집합(Dataset) 변수: OutputDS

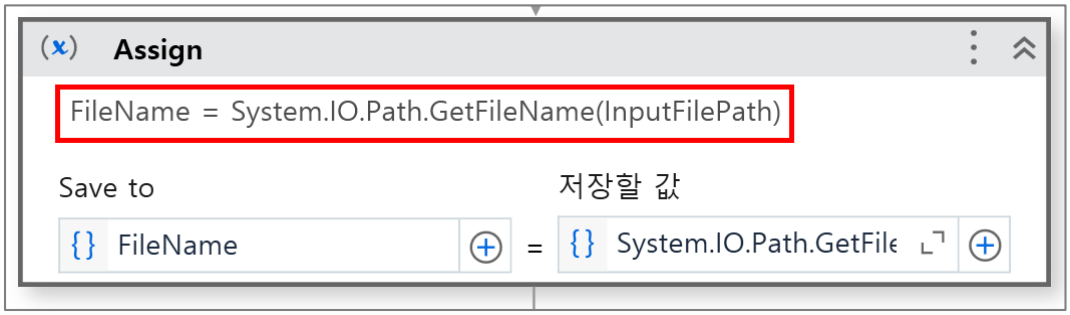
- Dataset 이란?: DataTable 의 Collection



Step2. 결과 파일 이름 및 다운로드 Path 설정

- 파일 이름 변수: FileName

- 값: FileName = System.IO.Path.GetFileName(InputFilePath)

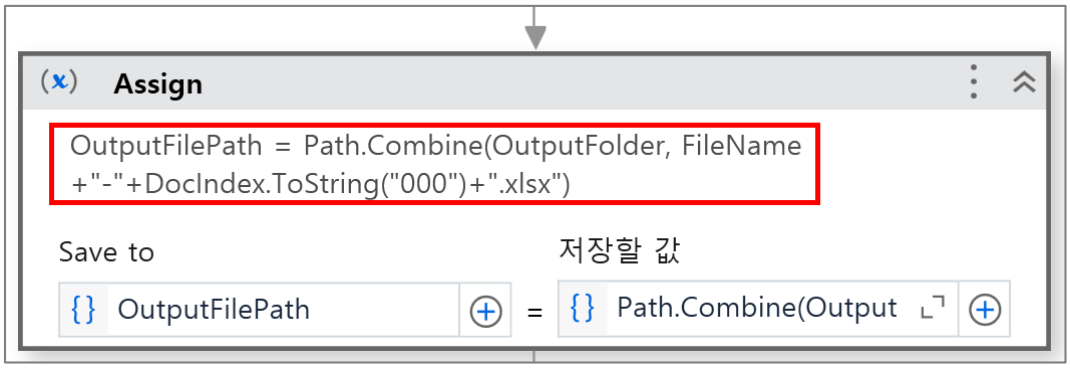


- 파일 이름 변수: OutputFilePath

- 값: OutputFilePath = Path.Combine(OutputFolder, FileName+"-"+DocIndex.ToString("000")+".xlsx")

* DocIndex.ToString("000") : 정수형 변수 DocIndex 를 문자열로 변환할 때, 최소 3 자리 숫자로 표현하겠다는 의미입니다.

- 예를 들어, DocIndex 가 5 일 경우 "005"로 변환됩니다.
- DocIndex 가 23 일 경우 "023"로 변환됩니다.
- DocIndex 가 123 일 경우 "123"으로 그대로 변환됩니다.

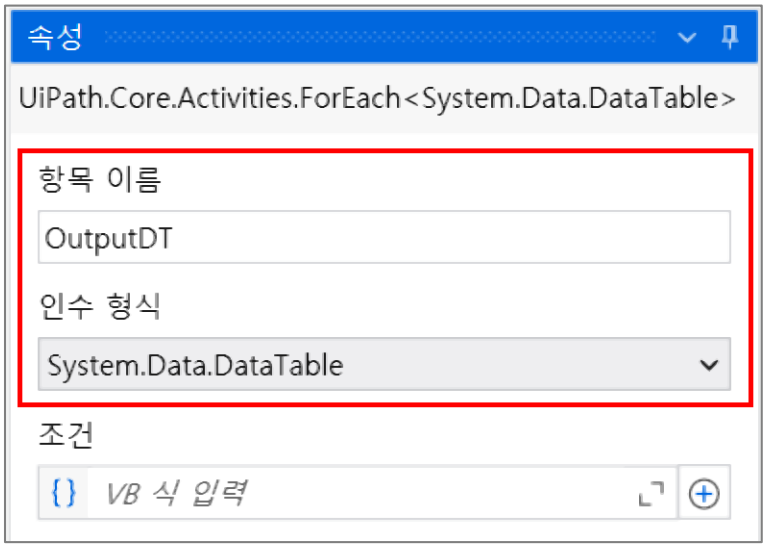


Step3. Excel 파일로 추출

- For Each 액티비티 드래그 앤 드롭

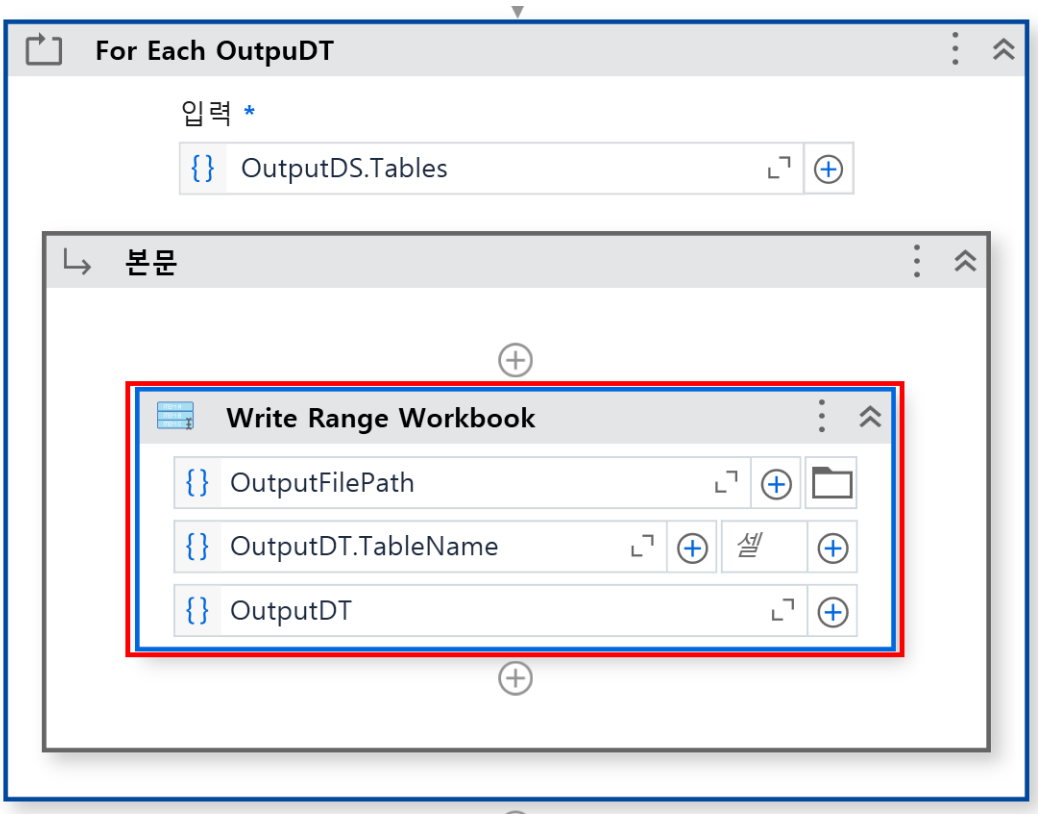


- For Each 속성 변경

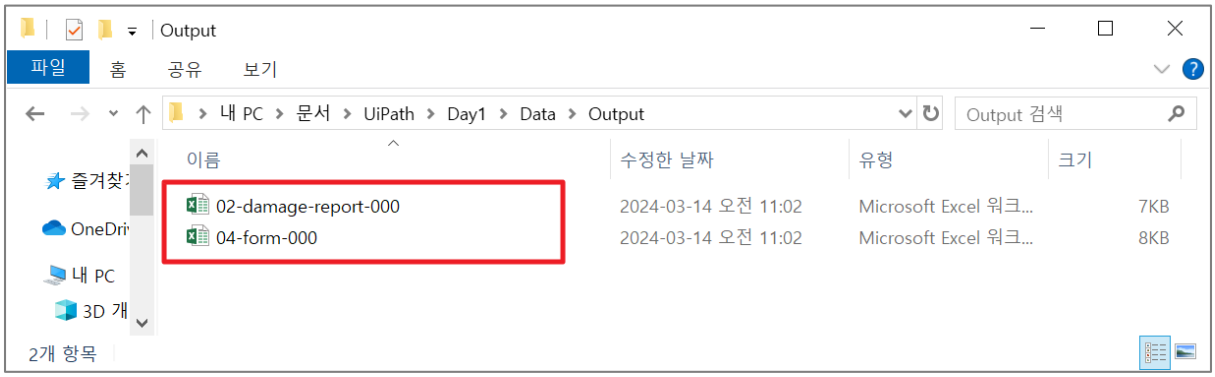


- Write Range Workbook 액티비티 드래그 앤 드롭

- 속성에서 머리글 추가 체크박스 선택

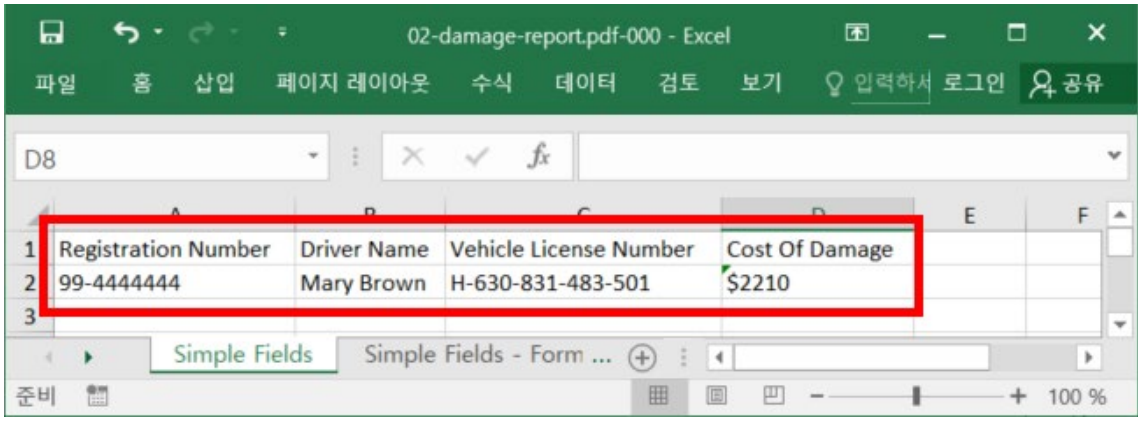


Step4. 전체 프로세스 실행 후 결과 확인 (InputFilePath 파일 경로 변경 필요)



Step5. 결과 확인

- damage report



- form

